



**UNIVERSIDAD DE LEÓN
ESCUELA DE INGENIERÍAS**

Actividad individual Bloque I

**Búsqueda de raíces y ajuste de modelos mediante métodos
libres de derivadas**

Autor:

Docente:

Dr. Miguel Ángel Navarro Burgos

Asignatura:

Matemática Finita II

Fecha de entrega:

11 de abril de 2026

Índice

1. Introducción	1
2. Dimensión teórica: modelado, formulación y justificación	1
2.1. Enfoque 1: método de Nelder-Mead (métodos numéricos clásicos)	1
2.2. Enfoque 2: algoritmos genéticos	2
2.3. Enfoque 3: muestreo de Monte Carlo	3
2.4. Comparación teórica de los tres enfoques	4
3. Dimensión aplicada: ajuste de modelos y validación computacional	5
3.1. Análisis comparativo y selección del mejor ajuste	6
4. Conclusiones	6
Referencias bibliográficas	7
Apéndice A. Uso de inteligencia artificial	8
A.1. Prompts utilizados	8
Apéndice B. Análisis exploratorio de datos	11
Apéndice C. Gráficos adicionales	12

1. Introducción

En este informe se refleja el trabajo llevado a cabo para la realización de la actividad 1, donde se estudia la búsqueda de raíces de funciones vectoriales $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ sin derivadas ni garantías de regularidad, razón por la cual no podemos usar métodos como por ejemplo aquellos basados en gradientes. Se analizan de forma teórica tres enfoques (Nelder-Mead, algoritmos genéticos y muestreo de Monte Carlo) los cuales se aplican computacionalmente para ajustar modelos lineales y no lineales sobre el dataset datos.csv. Todo el código está en el Jupyter Notebook.

2. Dimensión teórica: modelado, formulación y justificación

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ una función vectorial continua. Se desea encontrar un punto $\mathbf{x}^* \in \mathbb{R}^n$ tal que $f(\mathbf{x}^*) = \mathbf{0}$. No se asume que f sea diferenciable, convexa ni analítica. La función puede estar definida únicamente de forma implícita, como la salida de una simulación numérica o un modelo de tipo caja negra, lo que impide utilizar métodos que requieran derivadas o propiedades de regularidad. [7]

2.1. Enfoque 1: método de Nelder-Mead (métodos numéricos clásicos)

Tras sopesar el uso de diversos métodos numéricos clásicos, se optó por emplear el método de Nelder-Mead (véase Prompt 2, Anexo A). Este método se trata de un algoritmo de optimización que realiza transformaciones sobre un símplex (figura de $n + 1$ vértices en $\mathbb{R}^n$). El algoritmo evalúa la función objetivo en cada uno de los $n + 1$ vértices, y en el que el valor sea peor es el que es reemplazado en cada iteración, de forma que el símplex va avanzando de forma progresiva hacia el mínimo local más cercano. [5] [6]

a) Variables de decisión, dominio y función objetivo

Variable de decisión. Se define $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ como el vector de parámetros que se quiere optimizar. El objetivo es encontrar un vector de parámetros $\mathbf{x}^* \in \mathbb{R}^n$ de forma que $f(\mathbf{x}^*) = \mathbf{0}$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es la función vectorial de la cual queremos hallar las raíces.

Dominio de búsqueda. El problema se formula sobre $\mathbb{R}^n$, sin restricciones geométricas que afecten al dominio. Sin embargo, a la hora de construir el símplex inicial se define una región en forma de hiperrectángulo que está acotada (véase Prompt 3, Anexo A):

$$D = \{\mathbf{x} \in \mathbb{R}^n \mid L_i \leq x_i \leq U_i, i = 1, \dots, n\}$$

Los $n + 1$ vértices del símplex inicial se construyen dentro de D , pero el algoritmo no está restringido a permanecer en él tras las sucesivas transformaciones. Una mala elección de D puede dar lugar a convergencia prematura en un mínimo local [2].

Función objetivo. Al no poder buscar directamente las raíces, lo que se trata es de minimizar la siguiente función de error, ya que $E(\mathbf{x}^*) = 0$ si y solo si $f(\mathbf{x}^*) = \mathbf{0}$, es decir, el mínimo global de E es la raíz que se busca:

$$E(\mathbf{x}) = \|f(\mathbf{x})\|^2 = \sum_{i=1}^m f_i(\mathbf{x})^2$$

b) Idoneidad en ausencia de derivadas y regularidad

Nelder-Mead es adecuado cuando f tiene un comportamiento de ‘caja negra’, y por lo tanto no podemos obtener sus derivadas. Este algoritmo se basa en comparaciones entre valores de $E(x)$, por lo que es aplicable a funciones no diferenciables. Aunque teóricamente este método es muy sensible al ruido numérico, es ideal para nuestro problema ya que el ruido estadístico de los datos no afecta al algoritmo ya que la función que realmente explora Nelder-Mead (la suma de errores cuadráticos) configura una superficie que, aunque en general es compleja y no necesariamente convexa, permite un refinamiento local eficiente.

c) Ventajas, limitaciones y complejidad computacional

Ventajas. No necesita derivadas y es aplicable a funciones de caja negra. Presenta una baja complejidad por iteración, ya que, como se ha visto en el funcionamiento del método, requiere en general $n + 1$ evaluaciones de E por iteración. Además, cuenta con implementación directa en bibliotecas como SciPy.

Limitaciones. Puede quedar atrapado en mínimos locales. Para n grande ($n > 10$) el rendimiento empeora. La calidad de la solución depende mucho del punto inicial $\mathbf{x}_0$ y del tamaño inicial del simplex.

Complejidad computacional. La complejidad por iteración es $O(n)$ en evaluaciones de E [4].

2.2. Enfoque 2: algoritmos genéticos

Este método se basa en la selección natural. A partir de una población inicial de soluciones $P_0 = \{x_1, \dots, x_n\}$, se evalúa la calidad de cada individuo mediante una función llamada (*fitness*). El proceso (iterativo) selecciona a los mejores individuos para reproducirse con una probabilidad proporcional a su *fitness*, $P(x_i) = f(x_i) / \sum_j f(x_j)$, los cruza para generar descendencia, hijo = $C(x_{p_1}, x_{p_2})$, y les aplica mutaciones aleatorias, $x' = x + \epsilon$. Por último, la nueva generación reemplaza a los individuos menos aptos, $P_{t+1} = \text{selección}(P_t) \cup \{\text{hijos}\}$. Se repite hasta alcanzar la convergencia.

a) Variables de decisión, dominio y función objetivo

Variable de decisión. Cada individuo es representado por un vector $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$, donde cada $x_1, x_2, \dots, x_n$ representa un cromosoma de dicho individuo. El objetivo es encontrar

el individuo $\mathbf{x}^* \in \mathbb{R}^n$ tal que $f(\mathbf{x}^*) = \mathbf{0}$.

Dominio de búsqueda. El dominio D actúa como espacio genotípico global [8]:

$$D = [L_1, U_1] \times \cdots \times [L_n, U_n] \subset \mathbb{R}^n$$

La población inicial se distribuye sobre D de una manera uniforme, y los procesos propios de la evolución (operadores) generan descendencia (hijos) que se encuentran siempre dentro de los límites del dominio D .

Función objetivo. La función mediante la cual calculamos el *fitness* es la función del error: $E(\mathbf{x}) = \|f(\mathbf{x})\|^2$. La relación entre la aptitud (*fitness*) y el error es inversamente proporcional, es decir, a menor valor de E , mayor es su aptitud y por lo tanto, tal y como se describió en la definición del método, mayor su probabilidad de selección.

b) Idoneidad en ausencia de derivadas y regularidad

Los algoritmos genéticos no exigen que f sea derivable, solamente necesitan que se pueda evaluar. Debido a la mutación, el algoritmo realiza pequeñas variaciones que impiden que se quede atascado en mínimos locales. Por último, como trabaja con un conjunto de individuos (población), el algoritmo puede explorar varias zonas del problema al mismo tiempo, convirtiéndose en un método ideal para problemas complejos. [8] (véase Prompt 4, Anexo A).

c) Ventajas, limitaciones y complejidad computacional

Ventajas. No requieren derivadas ni hipótesis de regularidad sobre f . Una característica que hace que destaque frente a otros métodos como el previamente visto Nelder-Mead, es que realiza una exploración global de D , lo cual reduce enormemente la dependencia del punto inicial [1].

Limitaciones. El coste por generación es alto, requiere p evaluaciones de E , con p normalmente entre 50 y 500 individuos [8]. Además, tarda bastante en converger y requiere de ajustar un gran número de hiperparámetros.

Complejidad computacional. La complejidad por generación es $O(p \cdot n)$ donde n es la longitud del cromosoma y p el tamaño de la población. [8] [9]

2.3. Enfoque 3: muestreo de Monte Carlo

El método Monte Carlo es una técnica probabilística que trata de aproximar soluciones a problemas usando un muestreo aleatorio masivo. Se define dominio y se genera una gran cantidad de puntos aleatorios en su interior (cuantos más puntos, mayor precisión). Por último se observa cuántos puntos cumplen una condición específica. [11] [10]

a) Variables de decisión, dominio y función objetivo

Variable de decisión. Cada uno de los puntos aleatorios sigue una distribución uniforme $\mathbf{x}^{(i)} \sim \mathcal{U}(D)$. El objetivo es encontrar $\mathbf{x}^* \in \mathbb{R}^n$ tal que $f(\mathbf{x}^*) = \mathbf{0}$.

Dominio de búsqueda. Al igual que en los algoritmos genéticos el dominio es un hiperrectángulo [1][12]:

$$D = [L_1, U_1] \times \cdots \times [L_n, U_n] \subset \mathbb{R}^n$$

A diferencia de otros métodos que pueden explorar fuera de D , en este método si la solución se encuentra fuera de D nunca se encontrará.

Función objetivo. Se evalúa $E(\mathbf{x}) = \|f(\mathbf{x})\|^2$ en cada punto de la muestra independientemente. La estimación de la raíz es el punto con el menor error. En este algoritmo no hay ningún mecanismo que dirija el muestreo hacia regiones de menor error.

b) Idoneidad en ausencia de derivadas y regularidad

El único requisito de Monte Carlo es que f sea evaluable en cualquier punto de D , sin necesidad de continuidad, diferenciabilidad ni convexidad, lo que lo convierte en el método de referencia cuando el resto de enfoques son inaplicables por ausencia de estructura en f . Al no existir dependencia entre evaluaciones, es además trivialmente paralelizable.

c) Ventajas, limitaciones y complejidad computacional

Ventajas. Es el método más general de los tres ya que no necesita ninguna hipótesis sobre f y solo requiere fijar N y D , es decir, el número de puntos y el dominio [12].

Limitaciones. La precisión mejora con $\sqrt{N}$, no con N , por lo que para reducir el error a la mitad hay que cuadruplicar el número de muestras [13]. Como cada evaluación es independiente y no se tienen en cuenta evaluaciones anteriores, es menos eficiente que otros métodos para n pequeño.

Complejidad computacional. La complejidad es $\mathcal{O}(N)$ evaluaciones de E . El problema es que para mantener una cobertura del dominio aceptable, N tiene que crecer de forma exponencial al aumentar n , lo que hace que el método deje de ser viable en problemas de alta dimensionalidad. A esto se le llama la *maldición de la dimensionalidad* [12].

2.4. Comparación teórica de los tres enfoques

Presencia de múltiples raíces

Nelder-Mead es el más vulnerable ya que al partir de un único punto inicial, converge hacia la raíz más cercana sin explorar el resto del dominio. Los algoritmos genéticos son los más adecuados, ya que su población distribuida sobre D permite localizar varias raíces simultáneamente [8].

Aunque Monte Carlo ofrece también cobertura global, pero sin refinamiento local, por lo que la precisión depende exclusivamente de N .

Comportamiento ante paisajes de error casi planos

Nelder-Mead tiende a detener las transformaciones del símplex antes de tiempo al no detectar mejora suficiente. Los algoritmos genéticos continúan explorando gracias a la mutación, aunque la selección pierde efectividad cuando las diferencias de *fitness* son prácticamente nulas. Monte Carlo en cambio es el más robusto, ya que su muestreo aleatorio no depende de la variación de E .

Robustez ante ruido numérico

Nelder-Mead resulta bastante sensible, ya que el ruido distorsiona las transformaciones del símplex [2]. Sin embargo, los algoritmos genéticos presentan más robustez gracias a la diversidad de la población. Monte Carlo es más robusto ya que carece de dependencia entre evaluaciones. Para reducir el impacto del ruido [1], se proponen cambios como relajar el umbral de convergencia en Nelder-Mead para evitar que pare antes de tiempo, elevar la tasa de mutación en los genéticos y promediar múltiples evaluaciones de f en un mismo punto para Monte Carlo, reduciendo así la varianza del estimador E .

3. Dimensión aplicada: ajuste de modelos y validación computacional

Se han aplicado los tres métodos descritos en la dimensión teórica para minimizar el error cuadrático de dos modelos. Para el modelo lineal se minimiza:

$$S(\alpha_0, \alpha_1) = \sum_{i=1}^N (y_i - \alpha_0 - \alpha_1 x_i)^2$$

y para el modelo no lineal:

$$T(\beta_0, \beta_1, \beta_2) = \sum_{i=1}^N \left(y_i - \beta_0 - \beta_1 x_i^{\beta_2} \right)^2$$

Los dominios se fijaron de forma justificada por los rangos observados en el EDA (apéndice B). El criterio de parada de Nelder-Mead fue tolerancia $\varepsilon = 10^{-6}$. El GA se detuvo al completar el número máximo de generaciones. Monte Carlo no incluye refinamiento local, por lo que sus resultados representan la mejor muestra aleatoria dentro de D [14]. El código completo con los gráficos de convergencia se encuentra en el archivo.

Cuadro 1: Parámetros óptimos, métricas de ajuste y análisis de convergencia por combinación método-modelo. Elaboración propia.

Modelo	Método	ECM	R ²	Iter.	t (s)
Lineal	Nelder-Mead	683.52	0.3624	78	0.02
Lineal	GA	683.52	0.3624	500	4.52
Lineal	Monte Carlo	686.53	0.3596	—	1.15
No lineal	Nelder-Mead	679.67	0.3660	153	0.03
No lineal	GA	682.51	0.3633	1000	10.51
No lineal	Monte Carlo	745.46	0.3046	—	2.88

3.1. Análisis comparativo y selección del mejor ajuste

Como se observa en el Cuadro 1, para el modelo lineal los tres métodos convergen a soluciones se podría decir que idénticas. En el modelo no lineal, sin embargo, sí se pueden observar diferencias. Nelder-Mead obtiene el menor ECM (679.67) con un coste computacional muy bajo (0.03 s), mientras que el GA, para llegar a una solución ligeramente peor necesita bastante más tiempo (10.51 s). En este caso, Monte Carlo queda sin duda por detrás (ECM = 745.46). Esto es coherente con la dimensión teórica, ya que como se puede ver en esta, para n pequeño ($n = 3$), Nelder-Mead es el método más eficiente.

A la hora de seleccionar el modelo, el no lineal supera al lineal en todas las combinaciones, y aunque la diferencia en R^2 es pequeña (0.366 frente a 0.362), esto es lo que cabe esperar dado el alto nivel de ruido observado en el EDA. Dado que el patrón visual del gráfico de dispersión era claramente no lineal, se selecciona el modelo no lineal ajustado mediante Nelder-Mead ($\hat{y} = 83,06 + 0,81 x^{0,80}$) como modelo final.

4. Conclusiones

Tras el análisis comparativo de los tres enfoques de optimización libre de derivadas, se llega a la conclusión de que el método de Nelder-Mead es el más eficiente para el ajuste de los modelos propuestos, logrando el menor Error Cuadrático Medio ($ECM = 679,67$) en un tiempo de ejecución inferior a los otros métodos. Aunque los Algoritmos Genéticos demostraron una robustez superior para evitar mínimos locales, su alto coste computacional en este problema de baja dimensionalidad ($n \leq 3$) no justifica su uso. Por otro lado, el método de Monte Carlo mostró limitaciones con una convergencia lenta que resultó en un ajuste poco preciso. En cuanto al modelado, el modelo no lineal ($\hat{y} = \beta_0 + \beta_1 x^{\beta_2}$) presenta una capacidad predictiva superior al lineal, capturando de forma más precisa la complejidad observada en la fase de exploración de datos (EDA). Como posible implementación futura, la combinación de una búsqueda global inicial mediante algoritmos genéticos y un refinamiento local con Nelder-Mead podría dar lugar a una estrategia más robusta para problemas de mayor dimensionalidad.

Referencias bibliográficas

Referencias

- [1] Larson, J., Menickelly, M., & Wild, S. M. (2019). *Derivative-free optimization methods*. *Acta Numerica*, 28, 287–404.
- [2] Audet, C., & Hare, W. (2017). *Derivative-free and blackbox optimization*. Springer.
- [3] Conn, A. R., Scheinberg, K., & Vicente, L. N. (2009). *Introduction to derivative-free optimization*. Society for Industrial and Applied Mathematics (SIAM).
- [4] Department of Mathematics, University of Zagreb. (1999). *Applied mathematics and computation: proceedings*. Recuperado de <https://web.math.pmf.unizg.hr/applmath99/185-196.pdf>
- [5] MateFacil. (2023). *Método de la Secante | Ejemplo paso a paso*. [Archivo de video]. Recuperado de <https://youtu.be/j2gcuRVbwR0>
- [6] Métodos Numéricos. (2024). *¿Qué es el ajuste de modelos?*. [Archivo de video]. Recuperado de <https://youtube.com/shorts/opK-iG6zuL0>
- [7] Navarro Burgos, M. Á. (2026). *Actividad individual Bloque I: Matemática Finita II*. Material docente. Universidad de León, Escuela de Ingenierías.
- [8] Goldberg, D. E. (1989). *Genetic algorithms in search, optimization, and machine learning*. Addison-Wesley.
- [9] Eiben, A. E., & Smith, J. E. (2003). *Introduction to evolutionary computing*. Springer.
- [10] TheNewsToYou. (2023). *El método Montecarlo por Carlos Abellán CEO de Quside en #podcastNTY*. YouTube.
- [11] Santaolalla, J. (2015). *¿En qué consiste el método Montecarlo?*. YouTube.
- [12] Rubinstein, R. Y., & Kroese, D. P. (2016). *Simulation and the Monte Carlo method* (3.^a ed.). Wiley.
- [13] Robert, C. P., & Casella, G. (2004). *Monte Carlo statistical methods* (2.^a ed.). Springer.
- [14] Virtanen, P., et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.

Apéndice A Uso de inteligencia artificial

En este apartado se expone el uso de herramientas de IA, concretamente Claude (Anthropic), para la realización de la actividad. Se detallan los prompts utilizados, el resumen de la respuesta dada por la IA y una verificación de dicha respuesta mediante la revisión y contraste con las fuentes que la IA utilizó para llegar a dichas conclusiones.

Además del uso que se detalla a continuación, también se ha usado la herramienta de IA como apoyo en la redacción en L^AT_EX y la correcta citación de la bibliografía usada. Se consideran irrelevantes los prompts utilizados para este cometido, pues no se orientan al objetivo final de la actividad, sino a agilizar el proceso de creación del informe y mejorar su aspecto, orden y legibilidad.

Con este apartado se pretende demostrar que, a pesar de haber utilizado herramientas de inteligencia artificial, se ha realizado dicho uso de una manera ética, con mero propósito educativo y de agilización del trabajo, además de poder recibir explicaciones de una manera personalizada a mi forma de aprendizaje, mejorando así mi comprensión de la actividad y facilitándome su desarrollo.

A.1 Prompts utilizados

Prompt 1 — Implicaciones del parámetro β_2 (EDA)

Soy estudiante de Ingeniería de Datos. Tengo un dataset con 262 observaciones donde x va de 1 a 262 (todos positivos) e y va de 79.33 a 197.16. El gráfico de dispersión adjunto muestra la relación entre ambas variables. Quiero ajustar dos modelos: lineal ($y = \alpha_0 + \alpha_1 x$) y no lineal ($y = \beta_0 + \beta_1 x^{\beta_2}$). Basándote en el gráfico: ¿qué forma tiene la relación entre x e y ? ¿Qué implicaciones tiene que $x > 0$ para β_2 ?

Resumen de la respuesta generada por la IA: La IA identificó que el patrón del gráfico era no lineal y explicó que al ser $x > 0$ en todo el dominio, x^{β_2} está correctamente definido para todo $\beta_2 \in \mathbb{R}$, sin riesgo de caer en indeterminaciones.

Comprobación de los resultados: Se revisó el comportamiento matemático de funciones potenciales en los apuntes de Análisis Matemático I, donde se llegó a la siguiente conclusión: para $x < 0$ y β_2 decimal, x^{β_2} es imaginario; para $x = 0$ y $\beta_2 < 0$, queda indefinido. Como $x > 0$ en todos los datos, ambos casos quedan excluidos. Al comprobar que la respuesta generada por la IA era correcta, se tuvo en cuenta para la realización de la actividad.

Prompt 2 — Selección del método numérico clásico

Dime métodos numéricos clásicos para una función no diferenciable, convexa ni analítica que pueda estar definida únicamente de forma implícita, como salida de una simulación numérica o un modelo tipo caja negra, lo que impide usar métodos que requieran derivadas o propiedades

de regularidad. Para darme esta información, busca fuentes fiables y compártemelas para poder contrastar la información. Justifica en base a estas fuentes la elección de los métodos numéricos clásicos, da una explicación de por qué son válidos y dime de forma justificada cuál es la opción más correcta para este caso.

Resumen de la respuesta generada por la IA: La IA sugirió tres métodos candidatos (Nelder-Mead, Pattern Search y Powell) y dio una tabla comparativa de dichos métodos en aspectos como la robustez ante el ruido, el escalado o si estaban disponibles en SciPy.

Comprobación de los resultados: Se comprobó la existencia de las referencias aportadas por la IA para generar su respuesta [1] y [2]. Se descartó Powell por su gran sensibilidad al ruido, ya que, como se observó en el EDA, el dataset presentaba bastante ruido. Se seleccionó Nelder-Mead por su idoneidad para n pequeño y su implementación directa en SciPy.

Prompt 3 — Dominio de búsqueda en Nelder-Mead según Audet y Hare (2017)

Basándote en la fuente “Derivative-Free and Blackbox Optimization” de Audet y Hare (2017), Springer, explícame de forma sencilla y concisa cómo se define el dominio de búsqueda en el método de Nelder-Mead, concretamente qué forma matemática tiene y cuáles son sus implicaciones.

Resumen de la respuesta generada por la IA: La IA indicó que el dominio teórico del problema en Nelder-Mead es $\mathbb{R}^n$, sin restricciones geométricas impuestas. Señaló que el hiperrectángulo no es la estructura fundamental del método, sino que el algoritmo opera mediante un símplex de $n + 1$ vértices que se desplaza y deforma en el espacio a través de reflexión, expansión y contracción.

Comprobación de los resultados: Se contrastó la respuesta con [2], confirmando que la formulación clásica plantea el problema sobre $\mathbb{R}^n$ sin imponer forma concreta al dominio. El hiperrectángulo $D = \{\mathbf{x} \in \mathbb{R}^n \mid L_i \leq x_i \leq U_i\}$ es únicamente una convención práctica para acotar la región de inicialización del símplex, no una restricción formal del método. Tras verificar esta distinción, se corrigió la redacción del apartado a) del Enfoque 1 para reflejar correctamente esta separación entre dominio teórico y región de inicialización práctica.

Prompt 4 — Idoneidad de los algoritmos genéticos en ausencia de derivadas

Soy estudiante de Ingeniería de Datos. Estoy trabajando con una función f que no es diferenciable y puede estar definida como una caja negra. Quiero usar algoritmos genéticos para encontrar sus raíces. Explícame de forma sencilla por qué los algoritmos genéticos son adecuados en este contexto: ¿por qué no necesitan derivadas?, ¿cómo evitan quedarse atrapados en mínimos locales?, ¿qué ventaja tiene trabajar con una población de individuos en lugar de un único punto?

Resumen de la respuesta generada por la IA: La IA explicó que los algoritmos genéticos solo necesitan evaluar f , sin calcular derivadas. Además, la mutación introduce variaciones

aleatorias que evitan que el algoritmo se estanque en mínimos locales, y que al trabajar con una población se pueden explorar distintas zonas del espacio de búsqueda simultáneamente.

Comprobación de los resultados: Se contrastó con [8] y [9], donde se indica que la evaluación de la función de *fitness* es el único requisito operativo del algoritmo, y que el equilibrio entre exploración y explotación es precisamente una de las fortalezas de los algoritmos genéticos frente a métodos de búsqueda local.

Prompt 5 — Dominio de búsqueda en Monte Carlo

(Adjunté las fuentes Rubinstein & Kroese (2016) y Robert & Casella (2004)). Según estas fuentes, ¿cómo se define el dominio de búsqueda en el método de Monte Carlo?

Resumen de la respuesta generada por la IA: Basándose en las fuentes adjuntas, la IA explicó que el dominio de búsqueda se define como el soporte de la distribución de muestreo, es decir, el producto cartesiano de intervalos acotados para cada variable $D = [L_1, U_1] \times \cdots \times [L_n, U_n]$. Señaló que el dominio debe ser cerrado y acotado para que la distribución uniforme esté bien definida, y que si la solución está fuera de D , la probabilidad de encontrarla es estrictamente cero.

Comprobación de los resultados: Se contrastó la respuesta con [12], donde se define explícitamente el espacio de búsqueda como un conjunto compacto para Monte Carlo aplicado a optimización.

Prompt 6 — Limitaciones del método de Monte Carlo

(Adjunté las fuentes Rubinstein & Kroese (2016) y Robert & Casella (2004)). Según estas fuentes, ¿cuáles son las principales limitaciones del método de Monte Carlo? ¿crece el error con el número de muestras?

Resumen de la respuesta generada por la IA: La IA identificó dos limitaciones principales respaldadas por las fuentes. En primer lugar, la precisión crece con $\sqrt{N}$ y no con N , por lo que para reducir el error a la mitad es necesario cuadruplicar el número de muestras. En segundo lugar, para mantener una densidad de muestreo fija, N debe crecer exponencialmente con la dimensión n , lo que hace el método inviable en espacios de alta dimensionalidad.

Comprobación de los resultados: Se contrastó con [13], donde se demuestra la tasa de convergencia $\sqrt{N}$, y con [12], donde se discute la maldición de la dimensionalidad en el contexto del muestreo uniforme.

Prompt 7 — Revisión ortográfica

(Adjunté el pdf del trabajo) Para el siguiente pdf, indícame errores ortográficos que pueda haber, donde están y cómo solucionarlos.

Resumen de la respuesta generada por la IA: La IA indicó algunos errores ortográficos presentes en el informe, como por ejemplo: Pág. 5: “contruir el simplex” → construir el símplex (lleva tilde). Pág. 7: “poblaci on” → población. Pág. 8: “se prodría decir” → podría decirse. Pág. 8: “se obserbar” → observar. Pág. 8: “se puedo ver” → se pudo ver. Pág. 8: “heperparámetros” → hiperparámetros.

Comprobación de los resultados: Se comprobó que efectivamente esos errores existían y se procedió a su corrección.

Apéndice B Análisis exploratorio de datos

Se ha realizado un análisis exploratorio de los datos (EDA) con el objetivo de conocer mejor los datos con los que estamos tratando y sus características. En este informe se realizará un resumen de los resultados obtenidos, pero si se quiere ver el EDA más a detalle y con explicaciones más extensas se puede consultar el Jupyter Notebook de la actividad.

Se trata de un dataset con 262 datos, sin valores nulos. Los rangos de las dos variables son: $x \in [1; 262]$, $y \in [79,33; 197,16]$. Se realizó un gráfico de dispersión para poder ver la relación entre la variable x y la variable y (véase Prompt 1, Anexo A).




Figura 1: Diagrama de dispersión de los datos. Elaboración propia.

Apéndice C Gráficos adicionales




Figura 2: Gráfico de residuos comparativo entre el modelo lineal y no lineal utilizando los parámetros óptimos hallados por Nelder-Mead.