



universidad
de león



Escuela de Ingenierías Industrial, Informática y Aeroespacial

GRADO EN INGENIERÍA DE DATOS E INTELIGENCIA ARTIFICIAL

Trabajo de Fin de Grado

Sistemas de Movilidad Autónoma en Simuladores Urbanos mediante Redes Neuronales y Algoritmos Evolutivos

Autonomous Mobility Systems in Urban Simulators Using Neural Networks and
Evolutionary Algorithms

Autor: Sergio Alves Martín

Tutores: Sergio Rubio Martín / Alicia Merayo Corcoba

(Junio, 2026)

UNIVERSIDAD DE LEÓN
Escuela de Ingenierías Industrial, Informática y
Aeroespacial

GRADO EN INGENIERÍA DE DATOS E
INTELIGENCIA ARTIFICIAL
Trabajo de Fin de Grado

ALUMNO: Sergio Alves Martín

TUTORES: Sergio Rubio Martín / Alicia Merayo Corcobá

TÍTULO: Sistemas de Movilidad Autónoma en Simuladores Urbanos mediante Redes Neuronales y Algoritmos Evolutivos

TITLE: Autonomous Mobility Systems in Urban Simulators Using Neural Networks and Evolutionary Algorithms

CONVOCATORIA: Junio, 2026

RESUMEN:

El trabajo desarrolla un sistema de movilidad autónoma para *CognitiveCarSimulatorReloaded*, simulador urbano en Unreal Engine 5 orientado a rehabilitación y valoración cognitiva con ASPAYM. La solución incorpora vehículos con sensores simulados, interpretación de señales y un controlador neuronal entrenado con algoritmos evolutivos, junto con persistencia de modelos y análisis de métricas CSV. La evaluación principal incluye 548 generaciones de entrenamiento y cuatro sesiones de test con 1134 evaluaciones: fitness máximo de 134959.45 en entrenamiento, 80104.07 en test y una tasa agregada de acierto del 57.50 %. Las pruebas posteriores se conservan como diagnóstico de regresiones, no como sustitución de esa referencia.

ABSTRACT:

This thesis develops an autonomous mobility system for *CognitiveCarSimulatorReloaded*, an Unreal Engine 5 urban simulator aimed at cognitive rehabilitation and assessment with ASPAYM. The solution adds vehicles with simulated sensors, traffic-sign interpretation and a neural controller trained through evolutionary algorithms, plus model persistence and CSV metric analysis. The main evaluation comprises 548 training generations and four test sessions with 1134 evaluations: maximum fitness values of 134959.45 in training and 80104.07 in testing, with an aggregate success rate of 57.50 %. Later runs are kept as regression diagnostics rather than as a replacement for that reference.

Palabras clave: simulación urbana, movilidad autónoma, redes neuronales, algoritmos evolutivos, Unreal Engine.

Firma del alumno:

VºBº Tutores:

Resumen

CognitiveCarSimulatorReloaded es un simulador urbano desarrollado en Unreal Engine 5 para apoyar actividades de rehabilitación y valoración cognitiva relacionadas con la conducción. Este Trabajo de Fin de Grado aborda una de las carencias detectadas en la versión previa del sistema: la ausencia de tráfico autónomo capaz de generar situaciones dinámicas y repetibles. El objetivo es diseñar e integrar una arquitectura de movilidad vehicular que perciba el entorno, actúe sobre un vehículo con físicas reales, aprenda mediante experimentación y produzca información suficiente para evaluar su comportamiento. La solución combina once sensores distribuidos en un campo de visión de 180 grados, variables dinámicas del vehículo y contexto de semáforos, stops y cedas. Estas señales forman un vector de 20 entradas para un perceptrón multicapa con 16 neuronas ocultas y dos salidas continuas de dirección y aceleración o frenado. La política de control se optimiza mediante un algoritmo evolutivo que conserva modelos históricos y de sesión, muta sus pesos y selecciona individuos con una función de aptitud instrumentada. El sistema incorpora persistencia de modelos, separación entre puntos y trayectorias de entrenamiento y test, validación de señalización y tratamiento específico de rotondas. Cada ejecución exporta métricas a CSV; los scripts de Python verifican su integridad y generan informes y visualizaciones reproducibles. La evaluación principal utiliza el entrenamiento `train_2026-06-18_11-21`, con 548 generaciones y 16432 registros, y cuatro sesiones posteriores de test que reúnen 1134 evaluaciones sobre 54 puntos de aparición. El mejor fitness alcanza 134959.45 en entrenamiento y 80104.07 en test. Se obtienen 652 aciertos, una tasa del 57.50 % y un intervalo de confianza de Wilson al 95 % entre el 54.60 % y el 60.34 %. El 40.04 % de las evaluaciones termina en colisión y el 2.29 % en infracción normativa; las métricas de rotonda señalan además una recompensa neta negativa y un 33.63 % de colisiones por entrada. Las pruebas posteriores del 22, 23, 26 y 29 de junio no sustituyen esta referencia: el día 22 conserva un 52.91 % de acierto, el día 26 combina una sesión pobre con otra favorable y queda en un 49.89 % agregado, y el día 29 vuelve a caer al 30.42 % con `STOP_VIOLATION` como causa dominante. El proyecto ofrece así una base funcional y medible, pero confirma que cada cambio de recompensa o señalización debe someterse a bloques repetidos antes de considerarse estable.

Abstract

CognitiveCarSimulatorReloaded is an urban driving simulator developed in Unreal Engine 5 to support cognitive rehabilitation and assessment activities related to driving. This Bachelor's Thesis addresses one of the main limitations identified in the previous version of the system: the lack of autonomous traffic capable of producing dynamic and repeatable situations. The objective is to design and integrate a vehicle mobility architecture that perceives its surroundings, controls a physically simulated car, learns through experimentation and produces enough information to evaluate its behaviour. The solution combines eleven sensors distributed across a 180-degree field of view, vehicle dynamics and contextual information from traffic lights, stop signs and yield signs. These signals form a 20-input vector for a multilayer perceptron with 16 hidden neurons and two continuous outputs for steering and acceleration or braking. The evolutionary process preserves historical and session models, mutates their weights and selects individuals through an instrumented fitness function. The system provides model persistence, separate training and test spawn points and routes, traffic-control validation and dedicated roundabout handling. Each run exports CSV metrics that are checked and analysed by reproducible Python scripts. The main evaluation uses `train_2026-06-18_11-21`, comprising 548 generations and 16432 vehicle records, followed by four test sessions with 1134 evaluations across 54 spawn points. Maximum fitness reaches 134959.45 in training and 80104.07 in testing. The tests produce 652 successes, a 57.50 % success rate and a 95 % Wilson confidence interval from 54.60 % to 60.34 %. Collisions account for 40.04 % of evaluations and traffic-rule violations for 2.29 %; roundabout telemetry also reveals a negative net reward and collisions in 33.63 % of recorded entries. Later tests on 22, 23, 26 and 29 June do not replace this reference: 22 June remains close with a 52.91 % success rate, 26 June combines one weak run and one favourable run into a 49.89 % aggregate result, and 29 June drops again to 30.42 % with `STOP_VIOLATION` as the dominant cause. The project therefore provides a functional and measurable baseline while showing that every reward or traffic-control change must pass repeated testing before it can be considered stable.

Índice general

1. Estudio del problema	1
1.1. Introducción	1
1.2. Contexto	2
1.3. Problema que se resuelve	2
1.4. Objetivo general	3
1.5. Objetivos específicos	4
1.6. Estructura del trabajo	4
2. Estado del arte	5
2.1. Simuladores de conducción	5
2.2. Agentes autónomos en entornos urbanos	5
2.3. Redes neuronales y neuroevolución	6
2.4. Retos específicos	7
3. Tecnologías y herramientas	8
3.1. Unreal Engine 5	8
3.2. Sistema de físicas Chaos Vehicle	8
3.3. Raycasting y percepción local	9
3.4. Red neuronal	9
3.5. Algoritmos evolutivos	10
3.6. Análisis de datos	10
3.7. Control de versiones	11
4. Gestión del proyecto	12
4.1. Metodología	12
4.2. Cronología de decisiones	12
4.3. Línea evolutiva del desarrollo	14
4.4. Alcance	15
4.5. Gestión de riesgos	16
4.6. Estimación de recursos y presupuesto	17
5. Núcleo del trabajo	18
5.1. Descripción general de la solución	18
5.2. Subsistemas	18
5.2.1. Gestor evolutivo	18
5.2.2. Controlador de IA y red neuronal	19
5.2.3. Percepción mediante sensores	21

5.2.4. Sistema de fitness	21
5.2.5. Semáforos	22
5.2.6. Stop y ceda el paso	22
5.2.7. Rotondas	23
5.3. Pipeline experimental	23
6. Resultados	24
6.1. Datos analizados	24
6.2. Resumen cuantitativo	25
6.3. Evolución del entrenamiento	25
6.4. Evaluación de test	27
6.5. Razones de finalización	28
6.6. Comportamiento ante señalización	28
6.7. Comportamiento en rotondas	29
6.8. Dificultad por puntos de aparición	29
6.9. Pruebas posteriores hasta el 29 de junio	29
7. Normativa y accesibilidad	31
7.1. Protección de datos	31
7.2. Seguridad y uso responsable	31
7.3. Accesibilidad	32
8. Conclusiones y líneas futuras	33
8.1. Conclusiones	33
8.2. Aportaciones realizadas	34
8.3. Problemas encontrados	35
8.4. Líneas futuras	36
Agradecimientos	37
Bibliografía	38
A. Fuentes analizadas	A-1
A.1. Documentación administrativa y de formato	A-1
A.2. Actas de reunión	A-1
A.3. Descripciones del programa	A-2
A.4. Resultados experimentales	A-2
A.5. Conversaciones con asistentes de IA	A-3
B. Prompts utilizados	B-1
B.1. Criterio de documentación	B-1
B.2. Material revisado	B-1
B.3. Prompts depurados incorporados	B-2

Índice de figuras

Figura 6.1. Tendencia del fitness en el entrenamiento del 18 de junio de 2026. 26

Índice de tablas

Tabla 4.1.	Principales hitos y decisiones documentadas en reuniones.	13
Tabla 4.2.	Línea evolutiva del desarrollo técnico.	14
Tabla 4.3.	Riesgos principales del proyecto.	16
Tabla 6.1.	Resultados principales del entrenamiento y del bloque de test del 18 de junio de 2026.	25
Tabla 6.2.	Evolución de los bloques de test archivados en junio de 2026. . . .	27
Tabla B.1.	Conversaciones de IA revisadas para el anexo de prompts.	B-1

Glosario

ASPAYM	Asociación/Fundación colaboradora orientada a mejorar la calidad de vida de personas con lesión medular, gran discapacidad física y daño cerebral adquirido.
Blueprint	Sistema visual de programación de Unreal Engine empleado para implementar lógica de juego, interacción, controladores y sistemas de simulación.
Chaos Vehicle	Sistema de físicas de Unreal Engine 5 utilizado para simular el comportamiento dinámico del vehículo.
DCA	Daño Cerebral Adquirido.
Fitness	Función de aptitud que cuantifica el comportamiento de cada vehículo autónomo durante una generación evolutiva.
NavMesh	Malla de navegación utilizada por motores de videojuegos para calcular rutas transitables. En este proyecto fue estudiada y posteriormente descartada como solución principal para vehículos.
NPC	<i>Non-Player Character</i> ; agente controlado por el sistema y no por el usuario.
Raycasting	Técnica de consulta geométrica que lanza rayos o trazas desde un actor para detectar obstáculos y distancias en el entorno.
RN	Red neuronal artificial.
UE5	Unreal Engine 5.

Capítulo 1

Estudio del problema

1.1 INTRODUCCIÓN

Esta memoria presenta el desarrollo de un sistema de movilidad autónoma para *CognitiveCarSimulatorReloaded*, un simulador urbano de conducción orientado a actividades de rehabilitación y valoración cognitiva. El trabajo parte de una ciudad ya construida en Unreal Engine 5 y aborda una carencia concreta de la versión previa: la ausencia de tráfico autónomo capaz de generar situaciones dinámicas, repetibles y medibles para el usuario.

La solución propuesta integra vehículos controlados por una red neuronal ligera, sensores simulados mediante raycasting, contexto de señalización y un algoritmo evolutivo que ajusta los pesos de la red dentro del propio simulador. El controlador no desplaza el coche de forma directa, sino que produce dirección y aceleración o frenado sobre el sistema físico de Unreal Engine. Esta decisión obliga a tratar problemas propios de la conducción, como inercia, giro, frenada, límites de calzada, stops, cedas, semáforos e intersecciones.

El proyecto también incorpora una parte importante de instrumentación y análisis de datos. Cada ejecución exporta métricas por vehículo y resúmenes por generación, que después se validan con scripts de Python. Esta trazabilidad permite distinguir entre una mejora real, un comportamiento visualmente aceptable pero incorrecto y una regresión causada por cambios en fitness o señalización.

La evaluación principal utiliza el entrenamiento del 18 de junio de 2026 y cuatro sesiones de test posteriores sobre 54 puntos de aparición. En ese bloque se obtiene una tasa de acierto del 57.50 %, con 652 aciertos sobre 1134 evaluaciones, un 40.04 % de colisiones y un 2.29 % de fallos legales. Los bloques posteriores muestran que el sistema todavía no es robusto: el día 23 la tasa de acierto cae al 16.27 %, el día 26 queda en un 49.89 % agregado con resultados muy desiguales entre sesiones y el día 29 baja al 30.42 %, de nuevo con STOP_VIOLATION como causa dominante. Por tanto, el resultado actual debe entenderse como una base funcional y medible sobre la que seguir iterando, no como una solución final lista para validación clínica.

1.2 CONTEXTO

La conducción es una actividad compleja que exige coordinación motora, atención sostenida, atención dividida, interpretación de señales, percepción espacial y toma de decisiones bajo restricciones temporales. En personas que han sufrido daño cerebral adquirido, estas capacidades pueden verse alteradas aunque existan adaptaciones físicas que permitan manejar un vehículo. Por ello, antes de exponer al paciente a situaciones reales de tráfico, resulta de interés disponer de entornos controlados donde observar, entrenar y valorar comportamientos de conducción de forma segura.

El proyecto *CognitiveCarSimulatorReloaded* nace dentro de esta necesidad. La propuesta original define un simulador realista de conducción urbana para entrenamiento y valoración de alteraciones cognitivas tras un daño cerebral adquirido, desarrollado en colaboración con ASPAYM [1]. La versión inicial del simulador, desarrollada durante el curso 2024-2025, ya incluía un entorno urbano, vehículo, interacción física, señalización y registro de datos [2]. Sin embargo, las evaluaciones posteriores identificaron una carencia clave: el escenario necesitaba tráfico autónomo y dinámico para trasladar al usuario a una situación más realista.

El presente TFG aborda esa carencia desde el ámbito de la Ingeniería de Datos e Inteligencia Artificial. El foco no se sitúa en crear un simulador desde cero, sino en diseñar e integrar modelos de movilidad autónoma capaces de aprender comportamientos de conducción dentro de un entorno urbano ya existente. El trabajo combina redes neuronales, algoritmos evolutivos, sensores simulados, control físico en tiempo real y análisis de datos experimentales.

1.3 PROBLEMA QUE SE RESUELVE

El problema técnico principal consiste en conseguir que agentes autónomos, inicialmente vehículos, circulen por un mapa urbano de forma suficientemente estable, medible y compatible con las normas básicas de tráfico. A diferencia de un recorrido prefijado, un agente autónomo debe responder a múltiples condiciones locales: límites de la calzada, obstáculos, intersecciones, semáforos, señales de stop, señales de ceda el paso y cambios en su propio estado dinámico.

Durante el desarrollo se evaluaron soluciones deterministas de navegación, como el uso de NavMesh o recorridos mediante *Path Finding*. Estas aproximaciones resultaron útiles como punto de partida, pero presentaron limitaciones para el objetivo clínico y experimental del simulador: rutas rígidas, giros poco naturales, dificultad para representar la toma de decisiones local y menor capacidad de adaptación a situaciones imprevistas. Como consecuencia, el proyecto evolucionó hacia una solución basada en percepción local mediante sensores y aprendizaje evolutivo.

Además, el problema requiere que el comportamiento obtenido sea observable y explicable. No basta con que los vehículos se desplacen por el escenario; es necesario registrar por qué avanzan, se detienen, colisionan, incumplen una señal o completan correctamente una maniobra. Esta trazabilidad condiciona la arquitectura de la solución, porque cada decisión de control debe poder relacionarse con sensores, contexto de tráfico, componentes de fitness y resultados experimentales.

1.4 OBJETIVO GENERAL

El objetivo general del trabajo es desarrollar e integrar un sistema de movilidad autónoma para un simulador urbano de conducción, basado en redes neuronales y algoritmos evolutivos, que permita entrenar, evaluar y analizar vehículos autónomos dentro de Unreal Engine 5.

De forma complementaria, el proyecto busca dejar una base reutilizable para futuras ampliaciones del simulador. La movilidad vehicular autónoma actúa como primer bloque técnico sobre el que podrán incorporarse perfiles de conducción, otros agentes dinámicos y escenarios de validación más cercanos al uso clínico previsto.

1.5 OBJETIVOS ESPECÍFICOS

El objetivo general se concreta en tareas que cubren el ciclo completo de desarrollo: conocer el punto de partida, construir el controlador, entrenarlo y comprobar su comportamiento con datos. No se plantea únicamente obtener vehículos que se desplacen por el mapa; también se busca que las decisiones de diseño queden justificadas y que los resultados puedan repetirse y compararse. A partir de este criterio, los objetivos específicos son:

- Analizar el estado inicial del simulador y las restricciones técnicas heredadas de la versión previa.
- Diseñar una arquitectura de percepción para vehículos autónomos basada en sensores simulados mediante raycasting.
- Implementar una red neuronal ligera capaz de transformar entradas sensoriales y de contexto en acciones de conducción.
- Diseñar un proceso de entrenamiento evolutivo que evalúe poblaciones de vehículos, seleccione individuos destacados y aplique mutaciones sobre sus pesos.
- Integrar señales de tráfico, semáforos, stops y cedas en la lógica de percepción, parada y validación de la IA.
- Construir una función de fitness interpretable, con componentes positivos y penalizaciones, que permita medir progreso, errores y comportamientos no deseados.
- Generar registros experimentales en CSV y analizarlos mediante scripts reproducibles para evaluar entrenamiento y test.
- Identificar limitaciones, riesgos y líneas futuras para ampliar la movilidad autónoma a perfiles de conductor, peatones, bicicletas y otros agentes.

1.6 ESTRUCTURA DEL TRABAJO

El documento se organiza en ocho capítulos principales. Tras este estudio del problema, el capítulo 2 resume el estado del arte y los retos asociados a simuladores, agentes autónomos y aprendizaje evolutivo. El capítulo 3 describe las tecnologías y herramientas utilizadas. El capítulo 4 presenta la gestión del proyecto, la evolución temporal, los riesgos y una estimación preliminar de recursos. El capítulo 5 desarrolla el núcleo técnico de la solución. El capítulo 6 recoge los resultados experimentales. El capítulo 7 trata normativa, protección de datos y accesibilidad. Finalmente, el capítulo 8 expone conclusiones, aportaciones y líneas futuras.

Capítulo 2

Estado del arte

2.1 SIMULADORES DE CONDUCCIÓN

Los simuladores de conducción permiten reproducir situaciones de tráfico en un entorno controlado, repetible y seguro. En el ámbito formativo se utilizan para entrenar maniobras, respuesta ante eventos inesperados y familiarización con normas de circulación. En el ámbito sanitario, su valor reside en que permiten observar capacidades cognitivas y motoras sin exponer al usuario a riesgos reales. La versión previa de *CognitiveCarSimulator* ya se apoyaba en esta idea: un entorno urbano en Unreal Engine donde registrar tiempos de reacción, velocidades, colisiones y datos exportables para especialistas [2].

Para que un simulador de rehabilitación resulte convincente, el entorno no puede limitarse a una vía vacía. El usuario debe compartir la escena con otros agentes que creen carga cognitiva: vehículos que se detienen, peatones que cruzan, ciclistas, señales y elementos dinámicos. La propuesta de *CognitiveCarSimulatorReloaded* identifica precisamente esa necesidad al plantear IAs conductoras configurables, peatones, bicicletas y animales como ampliaciones progresivas del simulador [1].

2.2 AGENTES AUTÓNOMOS EN ENTORNOS URBANOS

La navegación autónoma en videojuegos y simulación suele abordarse mediante técnicas deterministas, como grafos de rutas, splines o mallas de navegación. Estas técnicas son robustas cuando el objetivo es desplazar agentes por zonas transitables con trayectorias controladas, pero pueden producir comportamientos rígidos si se aplican directamente a vehículos físicos. Un coche no se desplaza como un personaje humano: tiene inercia, radio de giro, aceleración, frenada, fricción y restricciones de control continuas.

En este proyecto se comprobó esa diferencia durante las primeras iteraciones. El uso de NavMesh y Path Finding fue estudiado para permitir recorridos por la ciudad, pero las reuniones de seguimiento y los informes técnicos documentan problemas de rigidez, dificultad en intersecciones y falta de naturalidad. Por ello se adoptó una estrategia más cercana a la percepción local: el agente no sigue una ruta global cerrada, sino que interpreta distancias, estado del tráfico y contexto normativo para producir acciones continuas.

2.3 REDES NEURONALES Y NEUROEVOLUCIÓN

Las redes neuronales artificiales permiten aproximar funciones complejas a partir de entradas numéricas [7]. En este TFG se emplean como política de control: reciben sensores, velocidad y contexto de señalización, y producen dirección y aceleración/frenado. La configuración vigente es deliberadamente ligera para poder ejecutarse en tiempo real sobre múltiples vehículos: 20 entradas, una capa oculta de 16 neuronas y dos salidas continuas con activación hiperbólica.

El entrenamiento no se plantea como aprendizaje supervisado, ya que no se dispone de un conjunto amplio de trayectorias humanas etiquetadas dentro del simulador. En su lugar, se adopta un algoritmo evolutivo [8]. Cada individuo de una población representa un conjunto de pesos de la red neuronal. La simulación evalúa el comportamiento mediante fitness; los mejores pesos se conservan, se mutan y se reutilizan en generaciones posteriores. Este enfoque se sitúa dentro de la neuroevolución, aunque el proyecto mantiene fija la topología de la red y evoluciona únicamente sus pesos, a diferencia de métodos como NEAT que también modifican la estructura [9].

La elección de un enfoque evolutivo también facilita trabajar con objetivos parcialmente contradictorios. Un vehículo debe avanzar, pero no a cualquier precio; debe mantener velocidad útil, pero frenar ante obstáculos; debe explorar la ciudad, pero respetar stops, cedas y semáforos. En este contexto, el fitness actúa como mecanismo de equilibrio entre progreso, seguridad, cumplimiento normativo y estabilidad de la conducción.

2.4 RETOS ESPECÍFICOS

La revisión de las alternativas disponibles y las primeras pruebas sobre el simulador permitieron acotar los problemas que condicionaban la solución. Algunos proceden del propio vehículo físico y otros aparecen al trasladar un método de aprendizaje a un mapa urbano con cruces y señalización. Los principales retos identificados son:

- **Simulación física:** el control neuronal debe traducirse a entradas de un vehículo con físicas reales, evitando aceleraciones, frenadas o giros no plausibles.
- **Intersecciones:** los cruces concentran la mayor complejidad, porque combinan decisión de trayectoria, detección de límites, prioridades y otros vehículos.
- **Diseño de fitness:** una función de aptitud mal calibrada puede premiar estrategias no deseadas, como detenerse indefinidamente, avanzar demasiado despacio o compensar errores graves con comportamientos parciales.
- **Generalización por puntos de aparición:** el modelo debe funcionar en diferentes zonas del mapa, no únicamente en los puntos de entrenamiento más sencillos.
- **Coste computacional:** entrenar decenas de vehículos simultáneamente en Unreal Engine implica carga de CPU, GPU y física.
- **Trazabilidad:** al tratarse de un sistema experimental, es imprescindible registrar métricas suficientes para explicar por qué una iteración mejora o empeora.

Estos retos aparecen de forma combinada durante el desarrollo. Una mejora en sensores puede modificar el fitness, un cambio en intersecciones puede alterar la tasa de colisiones y una reducción de coste computacional puede afectar al número de generaciones evaluables. Por ello, el proyecto no se aborda como una única implementación cerrada, sino como un proceso de ajuste continuo apoyado en métricas y revisión experimental.

Capítulo 3

Tecnologías y herramientas

3.1 UNREAL ENGINE 5

Unreal Engine 5 es el motor sobre el que se desarrolla el simulador. Proporciona renderizado 3D, editor visual, sistema de actores, colisiones, físicas, Blueprints y herramientas de depuración [3, 5]. Su elección viene heredada de la versión inicial del proyecto y resulta coherente con los requisitos de realismo visual, interacción en tiempo real y despliegue del simulador como aplicación ejecutable.

El trabajo se implementa principalmente mediante Blueprints, lo que permite integrar lógica de IA, controladores, sensores y eventos de tráfico dentro del propio editor. Este enfoque facilita la iteración rápida, aunque introduce retos de mantenibilidad cuando los grafos crecen. Por ello se han documentado los Blueprints principales del gestor evolutivo, el controlador de IA, el vehículo autónomo y los actores de señalización. Las denominaciones concretas de estos módulos se recogen en el anexo de fuentes para mantener la trazabilidad técnica sin sobrecargar el texto principal.

3.2 SISTEMA DE FÍSICAS CHAOS VEHICLE

El vehículo se controla mediante el sistema de físicas Chaos Vehicles de Unreal Engine [4]. La red neuronal no mueve directamente el actor, sino que genera consignas continuas que se aplican al componente de movimiento del vehículo. La salida de dirección se envía como *steering input*; la salida de aceleración/frenado se interpreta de forma separada: valores positivos se aplican como acelerador y valores negativos como freno.

Esta separación es importante porque mantiene el comportamiento dentro de la física del motor. El agente aprende a actuar sobre el vehículo, pero la respuesta final depende de velocidad, fricción, inercia, contacto con el suelo y restricciones propias del modelo físico.

3.3 RAYCASTING Y PERCEPCIÓN LOCAL

La percepción del vehículo se implementa mediante trazas o rayos simulados, una técnica soportada por Unreal Engine para consultar colisiones a lo largo de una línea de la escena [6]. El controlador lanza once sensores en un ángulo de visión de 180 grados desde el vehículo. Cada sensor devuelve una distancia normalizada al primer obstáculo relevante, con valor cercano a 1 cuando no se detecta un obstáculo próximo y valores menores cuando existe un límite, pared, vehículo o borde de intersección.

Además de los sensores laterales y frontales, se calculan variables derivadas como la distancia frontal a obstáculo, la distancia del sensor izquierdo, la distancia del sensor derecho y la diferencia horizontal entre ambos. Estas magnitudes permiten construir una señal de centrado en carril y detectar correcciones equivocadas.

3.4 RED NEURONAL

La red neuronal empleada es un perceptrón multicapa ligero. Las primeras trece posiciones de su vector de entrada describen el movimiento y el espacio próximo al vehículo: velocidad longitudinal, velocidad angular y once distancias obtenidas mediante raycasting. Todas ellas se normalizan antes de ejecutar la inferencia para evitar que una magnitud domine a las demás únicamente por su escala.

Las siete posiciones restantes incorporan el contexto de señalización y el sesgo. Dos contienen el estado numérico del control activo y la distancia normalizada a la línea de parada; esta última solo se utiliza cuando hay un semáforo activo o una orden de parada, y vale 1 en el resto de situaciones. Otras cuatro posiciones forman una codificación *one-hot* que distingue entre semáforo, stop, ceda el paso o ausencia de control. La última posición es un sesgo constante. La configuración vigente suma así 20 entradas y permite que una misma lectura geométrica produzca respuestas distintas según la norma aplicable.

La capa oculta contiene 16 neuronas y utiliza $\tanh$ como función de activación. La capa de salida contiene dos neuronas, también con $\tanh$, de modo que sus valores se encuentran en el rango $[-1, 1]$. La primera salida controla dirección y la segunda controla aceleración o frenado. La arquitectura emplea 320 pesos entre entrada y capa oculta y 32 entre capa oculta y salida, 352 en total. La rutina de inferencia deduce el número esperado de entradas a partir de la longitud del primer bloque de pesos y comprueba ambas dimensiones antes de calcular las salidas. Esta guarda permite rechazar modelos incompatibles si la configuración cambia.

3.5 ALGORITMOS EVOLUTIVOS

El entrenamiento se basa en población, selección y mutación. El gestor evolutivo crea una población de vehículos, les asigna pesos iniciales o mutados, ejecuta la simulación y registra el fitness final de cada individuo. Los mejores pesos se guardan en disco como modelos reutilizables, distinguiendo entre el mejor modelo histórico y el mejor de sesión.

La configuración documentada el 17 de junio aplica una tasa ordinaria del 3 % a los descendientes del modelo histórico y del mejor modelo de sesión. Cada generación conserva además una copia sin mutar de ambos modelos y reserva el resto de la población a una mutación del 6 %, más intensa. El reparto equilibra explotación y diversidad sin reinicializar aleatoriamente individuos después de la primera generación. Los tamaños de población son parámetros editables del mapa; por ello, los valores efectivos se obtienen de la columna `N` de cada ejecución y no del valor por defecto del Blueprint.

3.6 ANÁLISIS DE DATOS

La instrumentación se diseñó para separar el detalle de cada vehículo de los resúmenes utilizados al comparar generaciones. Esta separación evita que los ficheros agregados crezcan innecesariamente y, al mismo tiempo, permite volver al registro individual cuando aparece una colisión, una penalización o un resultado anómalo. El proyecto genera tres ficheros principales:

- `Fitness_Debug.csv`, con métricas por coche: fitness, tiempo de vida, punto de aparición, razón de muerte, penalizaciones, bonus, datos de conducción, validación de stops y cedas, mutaciones, genealogía y comportamiento en rotondas.
- `Training_Summary.csv`, con resumen por generación de entrenamiento.
- `Test_Summary.csv`, con resumen por generación de test, incluyendo aciertos, errores y tasas.

El análisis posterior se realiza mediante Python, NumPy, Matplotlib y Seaborn. El script `analyse_current.py` valida la calidad de los CSV, detecta automáticamente si la sesión es de entrenamiento o test, genera informes textuales y produce gráficas de evolución, muertes, distribución de fitness, ranking por spawn, control de entradas, convergencia, diversidad, correlaciones, solapes entre coches y diagnósticos de paradas, cedas y rotondas. La versión actual calcula las métricas situacionales solo sobre filas con exposición al evento correspondiente, evitando que los ceros de coches que nunca alcanzaron una rotonda diluyan los promedios. El script `clean_unreal_log.py` permite limpiar logs de Unreal Engine conservando errores, avisos relevantes, mensajes de Blueprint y trazas propias del proyecto.

3.7 CONTROL DE VERSIONES

El trabajo se ha desarrollado con Git/GitLab en un contexto colaborativo. La documentación de seguimiento recoge tareas de limpieza de repositorio, configuración de `.gitignore`, eliminación de binarios pesados y organización de issues y milestones. Esta disciplina ha sido relevante porque el proyecto combina assets de Unreal, Blueprints, datos generados y modelos guardados.

Capítulo 4

Gestión del proyecto

4.1 METODOLOGÍA

El desarrollo se ha organizado mediante un enfoque iterativo e incremental. Las reuniones de seguimiento se celebraron de forma periódica, generalmente cada dos jueves, con participación de tutores, equipo técnico y personas vinculadas al proyecto original. En estas reuniones se revisaban avances, problemas, decisiones de arquitectura y siguientes objetivos. Esta dinámica se aproxima a una metodología ágil por sprints, aunque adaptada al contexto académico y a la disponibilidad del equipo.

La planificación inicial contemplaba una progresión amplia: semáforos y señales, IA vehicular, stops y cedas, perfiles de conductor, peatones, bicicletas, animales, diversidad de assets y optimización. El desarrollo real concentró el esfuerzo en construir una base sólida de IA vehicular, debido a la dificultad técnica de lograr navegación autónoma estable en la ciudad.

Durante el desarrollo se utilizaron asistentes de inteligencia artificial como apoyo de análisis y depuración. Su papel fue generar hipótesis, ordenar alternativas, proponer comprobaciones y ayudar a interpretar logs, Blueprints y CSV. Las respuestas no se incorporaron de forma automática: las decisiones se contrastaron con el comportamiento observado en Unreal Engine, las descripciones fechadas del programa, los resultados exportados y las pruebas de regresión. El anexo B documenta una selección depurada de estos prompts.

4.2 CRONOLOGÍA DE DECISIONES

La tabla 4.1 sintetiza los principales hitos recogidos en las actas de seguimiento.

Tabla 4.1. Principales hitos y decisiones documentadas en reuniones.

Fecha	Situación revisada	Decisión y consecuencia
27/11/2025	Integración de tráfico y elección de la primera IA.	Se prioriza la IA vehicular y se revisan semáforos dinámicos. Se descarta una malla dinámica para reconocer caminos por su coste de desarrollo.
11/12/2025	Representación de las rutas de la ciudad.	Se descarta mapear todo el escenario con splines y se prueba el <i>Path Finding</i> de Unreal. Se separan la decisión del modelo y la aplicación física del control.
17/12/2025	Interfaz entre la red y el vehículo.	Se fijan dos salidas continuas, dirección y aceleración/frenado, ambas dentro de $[-1, 1]$.
08/01/2026	Rigidez observada con <i>Path Finding</i> .	Se abandona esta opción como solución principal y se adopta entrenamiento evolutivo por prueba y error para aprender las maniobras básicas.
05/02/2026	Fallos en curvas e intersecciones.	Se introduce de forma provisional el etiquetado dinámico de bordes y se estudia cómo coordinar la elección de trayectoria con la percepción local.
19/02/2026	Falta de una validación conjunta de los subsistemas.	Se programa una demostración con red neuronal, sensores y bordes activos en todo el mapa.
05/03/2026	Demostración fallida y resultados difíciles de interpretar.	Se decide instrumentar la función de fitness y simplificar temporalmente los escenarios más complejos para localizar el origen de los fallos.
19/03/2026	Segunda demostración con navegación ya estable en buena parte del mapa.	Se acepta la base técnica, se planifica la reorganización del repositorio y se preparan la compilación para Windows y las siguientes mejoras.

Fuente. Elaboración propia a partir de las actas de seguimiento.

4.3 LÍNEA EVOLUTIVA DEL DESARROLLO

Además de los hitos de reunión, el proyecto ha seguido una evolución técnica marcada por pruebas que no siempre dieron un resultado utilizable a la primera. Esa evolución es relevante porque explica por qué la solución actual no se limita a una red neuronal aislada, sino que integra sensores, reglas de tráfico, persistencia de modelos, análisis de CSV y pruebas de regresión.

La tabla 4.2 resume las fases principales. No pretende listar cada cambio menor de Blueprint, sino recoger las decisiones que modificaron la dirección del trabajo.

Tabla 4.2. Línea evolutiva del desarrollo técnico.

Periodo	Prueba o problema	Aprendizaje incorporado
Noviembre-diciembre	Tráfico autónomo inicial y conexión red-vehículo.	Se comprobó que el objetivo debía centrarse primero en IA vehicular. La red quedó acoplada a dos salidas continuas, dirección y aceleración/frenado, para respetar la física del vehículo.
Enero-febrero	Rigidez de NavMesh y <i>Path Finding</i> .	Las rutas deterministas ayudaban a desplazar actores, pero no resolvían bien curvas, cruces ni control continuo. Se adoptó percepción local con sensores y aprendizaje evolutivo.
Marzo	Demostración fallida e interpretación insuficiente de los fallos.	La observación visual dejó de ser suficiente. Se instrumentó el fitness, se exportaron métricas por coche y se simplificaron temporalmente escenarios para localizar causas.
Marzo-abril	Precisión de parada, marcha atrás y coches inmóviles.	Se introdujeron penalizaciones específicas para parada imprecisa, retroceso y estancamiento injustificado. Las consultas de apoyo insistieron en evitar constantes arbitrarias y en derivar umbrales de variables ya presentes en el simulador.
Abril-mayo	Señalización, stops, cedas e intersecciones.	Los actores de tráfico pasaron a comunicar contexto al controlador. Los bordes de cruce se asociaron a dirección y trigger para que cada maniobra tuviera límites sensoriales coherentes.

Fuente. Elaboración propia a partir de actas, descripciones de Blueprints y análisis de datos.

Tabla 4.2. Línea evolutiva del desarrollo técnico (continuación).

Periodo	Prueba o problema	Aprendizaje incorporado
Mayo-junio	Persistencia de modelos, duplicados y selección para reentrenar.	Se revisó la estrategia de <code>SuperCarModel</code> , <code>SessionCarModel</code> y copias fechadas. También se compararon respaldos para evitar repetir tests sobre modelos equivalentes y para elegir candidatos de reentrenamiento con datos, no solo por fitness máximo.
Junio	Separación train/test, rotondas y análisis de regresión.	Se diferenciaron spawns y trayectorias por modo, se añadieron métricas de rotonda, solapes entre vehículos y diagnóstico de navegación fuera de calzada. Las sesiones del 22, 23, 26 y 29 de junio muestran que una mejora local del fitness puede degradar stops o generalización.

Fuente. *Elaboración propia a partir de actas, descripciones de Blueprints y análisis de datos.*

4.4 ALCANCE

El alcance funcional completado se centra en conseguir que los vehículos de tráfico puedan aprender y circular dentro del escenario existente. El trabajo no modifica el vehículo conducido por el paciente ni rediseña la ciudad: actúa sobre los coches autónomos, su controlador y los elementos del mapa que les proporcionan información. El resultado es un controlador capaz de transformar las salidas de la red neuronal en dirección, aceleración y frenado sobre el sistema físico de Unreal Engine.

Para alimentar ese controlador se ha incorporado percepción local mediante ray-casting y se han normalizado las variables que entran en la red. El aprendizaje se realiza con poblaciones de vehículos, selección, mutación y elitismo. Los pesos obtenidos pueden guardarse y cargarse en sesiones posteriores, lo que evita reiniciar el proceso cada vez que se abre el simulador. La evaluación se apoya en una función de fitness que combina avance, centrado, velocidad, cumplimiento de señales y penalizaciones por comportamientos no deseados.

Incluye además semáforos, stops, cedas, líneas de parada y validación de maniobras. En cruces y rotondas se registran trayectorias, entrada, salida, giro, colisiones y recompensa, con puntos de aparición separados para entrenamiento y test. Los CSV resultantes permiten comparar ejecuciones y localizar fallos repetidos por zona.

No forman parte de esta versión la implementación completa de peatones, bicicletas y animales, ni los perfiles de conductor diferenciados previstos en la propuesta inicial. Tampoco se aborda todavía una validación con pacientes. Estas ampliaciones requieren primero consolidar la navegación vehicular y disponer de un protocolo de prueba estable, por lo que se mantienen como trabajo posterior.

4.5 GESTIÓN DE RIESGOS

La tabla 4.3 relaciona los riesgos más relevantes con su impacto, probabilidad y estrategia de mitigación.

Tabla 4.3. Riesgos principales del proyecto.

Riesgo	Impacto	Prob.	Mitigación
Rigidez de navegación determinista	Comportamiento poco realista y baja utilidad clínica	Alta	Pivotar a percepción local con sensores y red neuronal.
Fitness mal calibrado	Aprendizaje de estrategias no deseadas	Alta	Instrumentar componentes, exportar CSV y analizar penalizaciones por familia de muerte.
Coste computacional	Entrenamientos lentos y dependencia de GPU/CPU	Media	Poblaciones moderadas, análisis offline y propuesta futura de modo sin renderizado.
Complejidad de intersecciones	Colisiones y violaciones normativas en cruces	Alta	Bordes dinámicos, zonas de cruce, validación de stops/cedas y separación train/test.
Sobreajuste a spawns concretos	Buen rendimiento local pero mala generalización	Media	Normalización por punto de aparición y test con spawns diferenciados.
Pérdida de conocimiento entrenado	Reinicio de aprendizaje entre sesiones	Media	Persistencia de modelos SuperCarModel y SessionCarModel.

Fuente. Elaboración propia a partir del seguimiento técnico del proyecto.

4.6 ESTIMACIÓN DE RECURSOS Y PRESUPUESTO

El proyecto se ha desarrollado durante las prácticas y el TFG, sin contratación externa ni compra específica de material. El recurso principal ha sido el tiempo dedicado a implementar Blueprints, ejecutar entrenamientos, revisar resultados y documentar cambios. Parte de ese tiempo no es programación directa: los entrenamientos ocupan el equipo durante periodos prolongados y obligan a repetir pruebas cuando cambia el fitness o la geometría de una intersección.

El trabajo técnico se ha realizado en un equipo capaz de ejecutar Unreal Engine 5 y las físicas de varios vehículos de forma simultánea. El control de versiones se ha gestionado con GitLab y el análisis con Python y bibliotecas libres. Unreal Engine no ha generado coste de licencia en este contexto académico. Por tanto, no existen costes directos de software ni de infraestructura; el hardware ya estaba disponible y solo correspondería imputar amortización y consumo eléctrico si se elaborase un presupuesto comercial.

En la memoria final, la valoración económica deberá convertir las horas efectivas de desarrollo y experimentación a un coste de ingeniería acordado con el tutor, y añadir la parte proporcional del equipo utilizado. Mantener separadas ambas partidas evita presentar como gasto real una licencia no pagada y permite actualizar el presupuesto cuando se cierre el registro definitivo de dedicación.

Capítulo 5

Núcleo del trabajo

5.1 DESCRIPCIÓN GENERAL DE LA SOLUCIÓN

La solución actual se estructura como un sistema de agentes autónomos entrenados dentro del simulador. Cada vehículo dispone de un controlador de IA que percibe el entorno, ejecuta una red neuronal, aplica acciones al sistema físico y registra métricas de comportamiento. Por encima de los vehículos existe un gestor evolutivo que crea poblaciones, asigna pesos, evalúa resultados, selecciona los mejores individuos y guarda modelos.

El sistema se completa con elementos de tráfico que comunican contexto a los controladores: semáforos, señales de stop, señales de ceda y zonas de cruce. Estos elementos no son meros objetos visuales, sino actores con lógica propia que activan zonas de detección, informan al vehículo de líneas de parada, controlan estados y aplican penalizaciones o bonus según el comportamiento observado.

5.2 SUBSISTEMAS

5.2.1 Gestor evolutivo

`BP_EvolutionManager` coordina el ciclo de entrenamiento y las ejecuciones de test. Al comenzar comprueba si existe un modelo histórico en `SuperCarModel`. Si lo encuentra, carga sus pesos; en caso contrario, inicializa una red aleatoria que servirá como punto de partida. Después actualiza la lista de puntos de aparición permitidos para el modo activo y crea la población de vehículos, asignando a cada coche su controlador y su red.

En la primera generación, el gestor parte de redes aleatorias o del modelo guardado según la configuración. A partir de la segunda, el índice del coche determina su familia: se conserva una copia sin mutar del mejor modelo histórico y otra del mejor modelo de la sesión; un 40 % de los puestos disponibles se muta desde cada una de esas dos semillas con una tasa del 3 %; los puestos restantes se derivan del modelo histórico con una tasa del 6 %. Cada coche registra el número de pesos modificados, su magnitud media y el fitness de su progenitor, lo que permite comprobar después si una familia de mutación aporta mejora real.

La generación termina cuando todos los vehículos han finalizado o han sido eliminados por alguna condición de muerte. El gestor ordena entonces los resultados y persiste el mejor de sesión en `SessionCarModel`. Solo sustituye `SuperCarModel` cuando el candidato mejora el fitness histórico y sus pesos son distintos; antes de sobrescribirlo guarda además una copia fechada del modelo anterior. La función `SaveWeightsToSlot` centraliza este proceso para que ambos ficheros almacenen los mismos bloques de pesos y el fitness asociado.

El modo de test reutiliza la misma infraestructura, pero desactiva la mutación y carga un modelo fijo. También emplea un conjunto de puntos de aparición distinto del utilizado para entrenar. Esta separación evita que una mejora aparente proceda únicamente de evaluar el coche en los recorridos que ya han condicionado su aprendizaje. Al terminar cada bloque, el gestor exporta tanto el resumen de la ejecución como los registros individuales necesarios para el análisis.

Una decisión relevante es la normalización por punto de aparición. La ciudad contiene zonas de dificultad desigual y comparar directamente el fitness de dos spawns puede favorecer al que comienza en una ruta sencilla. Por ello se conserva una referencia para cada punto y el resultado de cada coche se divide por la correspondiente antes de seleccionar sus pesos. Desde la versión del 17 de junio, esas referencias decaen en cada generación con un factor dependiente del historial, en lugar de conservar indefinidamente un máximo antiguo. La normalización no elimina las diferencias del mapa, pero evita que una ejecución excepcional bloquee de forma permanente la selección posterior.

5.2.2 Controlador de IA y red neuronal

`BP_AiController` actúa como intermediario entre red neuronal y vehículo físico. En cada tick comprueba que el vehículo controlado existe y no está muerto, prepara las entradas de red, ejecuta la inferencia y aplica las salidas al componente de movimiento.

Para evitar saltos bruscos, el controlador dispone de variables de suavizado como `MaxSteeringRate` y `MaxThrottleRate`. La versión documentada mantiene un seguimiento estable entre objetivo y entrada aplicada, con gap medio cero en los informes finales, lo que indica que la señal de control se está transmitiendo sin divergencias instrumentales.

La inferencia se calcula manualmente sobre arrays de pesos. Primero, cada una de las 16 neuronas ocultas combina las 20 entradas normalizadas con su bloque de pesos y aplica $\tanh$. Después, las dos salidas repiten la operación sobre esas 16 activaciones ocultas, de nuevo con $\tanh$, para producir dirección y aceleración o frenado. La operación puede expresarse como:

$$h_j = \tanh \left(\sum_{i=1}^{20} W_{j,i}^{(1)} x_i \right), \quad j = 1, \dots, 16. \quad (5.1)$$

$$y_k = \tanh \left(\sum_{j=1}^{16} W_{k,j}^{(2)} h_j \right), \quad k = 1, 2. \quad (5.2)$$

La ecuación 5.1 calcula la activación de cada neurona oculta a partir del vector de entrada. La ecuación 5.2 obtiene después las dos salidas de control a partir de esas activaciones. En estas expresiones, i recorre las entradas, j recorre las neuronas ocultas y k recorre las dos salidas. Por tanto, el uso de índices distintos sí está justificado: cada uno pertenece a una dimensión diferente de la red. En la segunda ecuación, j vuelve a aparecer como índice de suma porque las salidas se calculan a partir de todas las activaciones ocultas.

IH significa *Input to Hidden* y corresponde a las conexiones entre la entrada y la capa oculta. HO significa *Hidden to Output*, se denomina `WeightsHO` en los Blueprints y corresponde a las conexiones entre la capa oculta y las dos salidas. En las ecuaciones se ha usado $W^{(1)}$ y $W^{(2)}$ para que la notación matemática no dependa del nombre interno de los arrays.

Los pesos se almacenan en arrays unidimensionales. Por esa razón, el número de entradas esperado se obtiene dividiendo la longitud de `WeightsIH` entre el número de neuronas ocultas. A continuación se comprueba que ese resultado coincide con el vector de 20 entradas construido por el controlador, que `WeightsIH` contiene 20 por 16, es decir, 320 valores, y que `WeightsHO` contiene 16 por 2, es decir, 32 valores. Este cálculo dinámico permite detectar un modelo antiguo aunque la arquitectura vuelva a cambiar. Si faltan pesos o las dimensiones no son coherentes, se activa una guarda; después de cinco errores consecutivos, el coche se elimina con la razón de muerte `INVALID_BRAIN` para evitar que continúe circulando con una red inválida.

5.2.3 Percepción mediante sensores

El controlador lanza once trazas en abanico sobre 180 grados. Cada sensor devuelve una distancia normalizada hasta el primer elemento relevante. Los bordes de intersección se tratan con lógica específica: un borde virtual solo interviene en la lectura cuando su intención de dirección y su trigger coinciden con la decisión vigente del vehículo. Los bordes asociados a otras trayectorias se ignoran, de modo que una misma intersección puede contener límites sensoriales distintos para cada maniobra.

La decisión se modela mediante la enumeración `E_DirectionIntent`, con tres alternativas: primera, segunda y tercera salida. Al entrar en el trigger correspondiente, el vehículo selecciona aleatoriamente una de las opciones habilitadas para el modo de entrenamiento o de test. El controlador conserva tanto la dirección elegida como el trigger que la originó. Cada borde de intersección declara una o varias parejas formadas por dirección y trigger, y admite, cuando procede, cualquier trigger o cualquier dirección. De este modo, los rayos perciben únicamente los límites que delimitan la trayectoria seleccionada sin duplicar actores para los casos compartidos.

Las entradas sensoriales se combinan con información de tráfico. Si el vehículo entra en la zona de un semáforo, stop o ceda, el actor correspondiente comunica al controlador el tipo de control, la línea de parada y la distancia de entrada. Esta mezcla de percepción geométrica y contexto normativo permite que la red no dependa únicamente de distancia a obstáculos.

5.2.4 Sistema de fitness

La función de fitness se ha convertido en uno de los elementos centrales del proyecto. Las primeras versiones premiaban principalmente el avance, pero ese criterio por sí solo permitía comportamientos poco útiles: circular demasiado rápido cerca de un obstáculo, corregir hacia el lado equivocado o sobrevivir sin progresar. La función actual combina avance, velocidad útil y centrado estimado a partir de los sensores laterales. La revisión del 22 de junio hace lineal la contribución de la distancia frontal en el término de avance seguro; antes aparecía elevada al cuadrado y dominaba el resultado en determinadas situaciones.

Las penalizaciones se aplican cuando el vehículo marcha hacia atrás, permanece atascado, abandona la calzada o colisiona. Hay comprobaciones específicas para las correcciones de dirección y para el incumplimiento de semáforos, stops, cedas y zonas no navegables. La salida de calzada se controla con acumulación de penalización y umbrales temporales, de modo que una invasión breve no se trata igual que circular fuera de la zona válida. Completar correctamente un stop o un ceda produce una bonificación, pero esa recompensa se registra por separado para poder comprobar que no compensa una infracción grave ocurrida en otro momento de la ejecución.

Además del valor final, cada coche acumula métricas de aceleración, frenado, espera, dirección, contexto de parada, rotondas y solapes con otros vehículos. Estos solapes se registran como señal diagnóstica y no equivalen automáticamente a una muerte por colisión, pero ayudan a localizar zonas donde la densidad o la geometría generan conflictos. Esta instrumentación permite reconstruir qué componentes han dominado el resultado y distinguir, por ejemplo, una finalización por tiempo con recorrido útil de un vehículo inmóvil ante una señal. El desglose fue decisivo después de la demostración fallida del 5 de marzo de 2026, cuando la observación visual no bastó para localizar si el problema procedía de los sensores, de las restricciones o del propio cálculo de fitness.

5.2.5 Semáforos

El sistema de semáforos se compone de un controlador de intersección y de actores de semáforo. El controlador alterna fases norte-sur y este-oeste, incluyendo verde, ámbar y todo rojo. Cada semáforo mantiene materiales dinámicos para representar estado visual y una zona de sensor que detecta vehículos.

Cuando un vehículo entra en la zona, el semáforo comunica estado, línea de parada y distancia. Si el semáforo está en rojo o ámbar restrictivo, el controlador activa contexto de parada. Al salir de la zona, se comprueba si el vehículo atravesó la línea a una velocidad legal. El sistema aprende umbrales de velocidad legal a partir de muestras previas, evitando depender siempre de un valor fijo.

5.2.6 Stop y ceda el paso

Las señales BP_Sign_Stop y BP_Sign_Yield amplían la interacción normativa. En stop se exige detención suficiente dentro de una ventana dinámica antes de la línea, espera mínima y comprobación de cruce libre. Si se cumple, se aplica bonus y se libera el vehículo; si no, se aplica penalización y muerte por STOP_VIOLATION. En ceda se monitoriza velocidad, aproximación y disponibilidad de la zona de cruce, con penalización por YIELD_VIOLATION y bonus al completar correctamente.

La diferencia entre stop y ceda es metodológicamente importante. El stop requiere detención explícita; el ceda permite continuar si la velocidad y la prioridad son compatibles con la seguridad del cruce.

La validación del stop aprende de las maniobras legales una velocidad máxima y un tiempo mínimo de espera. Con ellos calcula una ventana de parada a partir de la distancia de entrada y del tiempo estimado hasta la línea. La revisión del 22 de junio simplifica el límite de validación a la suma del tiempo aprendido y el tiempo de aproximación. Como se muestra en el capítulo de resultados, este cambio coincide con un aumento acusado de STOP_VIOLATION y queda pendiente de recalibración.

5.2.7 Rotondas

Los triggers de intersección pueden marcarse como entrada o tramo de rotonda. Al entrar se registra la dirección escogida y se penaliza una velocidad superior a la aconsejada por la distancia frontal. Una nueva llegada a la entrada confirma que se ha completado una vuelta y aplica una bonificación proporcional a velocidad y espacio disponible. Durante el recorrido se acumulan giro, aceleración, colisiones y tiempo para la primera, segunda y tercera o posteriores salidas.

El fitness incluye además una penalización cuando el acelerador supera la distancia frontal normalizada dentro de la rotonda. En la revisión del 22 de junio, su escala se normaliza con el cociente entre el cuadrado de la velocidad máxima y la distancia máxima de visión, evitando que dependa de unidades incompatibles. Las recompensas de entrada y completado y las penalizaciones de aproximación y aceleración se exportan por separado; así puede comprobarse si el saldo neto favorece realmente completar la maniobra. Las descripciones del 29 de junio añaden además el análisis por salida, lo que permite detectar que las salidas tercera o posteriores concentran una parte desproporcionada de los fallos.

5.3 PIPELINE EXPERIMENTAL

Cada ejecución genera un registro por vehículo y un resumen por generación. Una vez terminada la sesión, los scripts de Python validan que ambos CSV contienen el número de filas esperado y que sus identificadores pueden alinearse. Solo después de esa comprobación se calculan los indicadores y se generan las gráficas. De esta manera, una fila incompleta o una generación duplicada no queda oculta dentro de una media agregada.

El diagnóstico comienza con *BestFit*, *MeanFit* y tiempo de vida, pero no termina en esas tres cifras. Las razones de muerte se agrupan por familias para separar colisiones, finalizaciones por tiempo y fallos normativos. Los bonus de stop y ceda se contrastan con el contexto de frenado, y los resultados se desglosan por punto de aparición. También se revisan correlaciones entre componentes, genealogía de mutaciones y métricas de rotonda por salida. El analizador excluye de los promedios situacionales los coches que no estuvieron expuestos al evento, lo que evita interpretar un cero por ausencia de rotonda como una maniobra correcta.

Este procedimiento convierte los datos en una guía de implementación. Cuando un indicador empeora, se consulta el CSV individual para localizar actores, intersecciones o spawns concretos. Después se ajusta el Blueprint afectado y se repite la prueba. Así el análisis cierra el ciclo entre implementación, simulación y revisión del resultado, sin depender únicamente de lo observado en pantalla.

Capítulo 6

Resultados

6.1 DATOS ANALIZADOS

La evaluación principal se desplaza a la configuración estable del 18 de junio de 2026. El entrenamiento `train_2026-06-18_11-21` contiene 548 generaciones completas en `Training_Summary.csv` y 16432 registros en `Fitness_Debug.csv`. La columna `N` declara 16440 vehículos, por lo que la cobertura del fichero de detalle es del 99.95 %. El informe automático no detecta alertas fuertes de desalineación, pero esta diferencia de ocho filas se conserva como limitación del conjunto.

La evaluación de test agrega las cuatro carpetas del 18 de junio: 12-41, 14-03, 14-39 y 14-51. En conjunto reúnen 21 ejecuciones completas y 1134 vehículos, con 21 observaciones para cada uno de los 54 puntos de aparición. Los cuatro informes presentan cobertura del 100 %, no descartan filas y clasifican todos los registros como test. La hora sirve únicamente para identificar cada carpeta; no se considera una variable experimental.

Los tamaños efectivos se obtienen de los CSV: 30 vehículos por generación de entrenamiento y 54 por ejecución de test. Esta comprobación es necesaria porque `PopulationSize` es editable en la instancia del mapa y su valor por defecto no describe necesariamente la sesión archivada. También se detectó que las carpetas de test 2026-06-11_11-55 y 2026-06-11_13-08 contienen un `Fitness_Debug.csv` idéntico; en las comparaciones se cuenta una sola vez.

Los bloques posteriores del 22, 23, 26 y 29 de junio se emplean como pruebas de regresión, no como nueva referencia principal. El primero conserva un rendimiento próximo al del día 18, aunque con más fallo legal. El día 23 muestra una degradación clara por `STOP_VIOLATION`. El día 26 combina una sesión corta poco satisfactoria con otra muy favorable, y el día 29 vuelve a caer por fallos legales. Por ello, los resultados principales del capítulo se apoyan en la configuración validada del 18 de junio y las sesiones posteriores se interpretan como evidencia para decidir las siguientes correcciones.

6.2 RESUMEN CUANTITATIVO

Tabla 6.1. Resultados principales del entrenamiento y del bloque de test del 18 de junio de 2026.


Métrica	Entrenamiento	Test agregado
Generaciones o ejecuciones	548	21
Registros de vehículos	16432	1134
<i>BestFit</i> máximo	134959.45	80104.07
<i>MeanFit</i> medio	30049.20	44619.47
<i>MeanFit</i> mediano	29922.54	45313.89
Tiempo medio de vida	74.98 s	77.91 s
Ejecuciones con <i>MeanFit</i> negativo	0.00 %	0.00 %
Colisiones	45.54 %	40.04 %
Fallos legales	2.12 %	2.29 %
LAZY	0.00 %	0.00 %
Tasa de acierto	No aplica	57.50 %

Fuente. Elaboración propia a partir de los CSV del proyecto.

El test no mejora el modelo durante la ejecución: carga pesos fijos y desactiva la mutación. Su mayor *MeanFit* responde a que cambia la distribución de puntos y trayectorias y a que cada ejecución cubre los 54 spawns de test. Por ello, la tabla 6.1 describe cada modo, pero no permite atribuir la diferencia de fitness únicamente a la calidad de la política.

6.3 EVOLUCIÓN DEL ENTRENAMIENTO

El mejor fitness se alcanza en la generación 56, con 134959.45, y el fitness medio máximo en la generación 33, con 44373.00. Ninguna de las 548 generaciones presenta *MeanFit* negativo.

Figura 6.1. Tendencia del fitness en el entrenamiento del 18 de junio de 2026.

Fuente. Análisis generado a partir de *Training_Summary.csv*.

La figura 6.1 muestra variabilidad persistente y obliga a separar supervivencia de aptitud. Entre las primeras y las últimas 50 generaciones, el *MeanFit* desciende un 17.5 %, de 33263.23 a 27433.45, mientras el tiempo medio aumenta un 43.1 %, de 54.83 a 78.46 segundos. El informe no identifica convergencia clara y registra 492 generaciones desde el último máximo. El modelo aprende a permanecer activo durante más tiempo, pero esa supervivencia no se traduce en una mejora monótona del objetivo.

De los 16432 registros, 8511 terminan por tiempo y 7483 por colisión. Los 348 fallos legales representan el 2.12 %, y no aparece ninguna muerte LAZY. El analizador marca 1985 posibles atascos ante stop y 1011 ante ceda dentro de las finalizaciones por tiempo. Son candidatos heurísticos, no infracciones confirmadas, pero explican por qué el tiempo de vida no puede utilizarse como único indicador.

La sesión registra además 5365 entradas en rotonda, 1075 completaciones confirmadas por una nueva entrada y 2350 colisiones dentro de ese contexto. La tasa de completado del 20.04 % es un límite inferior porque el contador solo confirma la maniobra al alcanzar de nuevo el trigger de entrada. El saldo específico de rotonda es negativo, con $-553966,78$ puntos acumulados, debido principalmente a la penalización de aceleración.

6.4 EVALUACIÓN DE TEST

El criterio implementado considera fallo cualquier colisión, infracción, estancamiento, corrección o marcha atrás incorrecta, vuelco, red inválida o navegación fuera de zona; también exige al menos 60 segundos de vida. El umbral de fitness de 25000 está configurado, pero desactivado mediante `TestUseFitness`. Con estas reglas, el bloque del 18 de junio obtiene 652 aciertos de 1134 evaluaciones, un 57.50 %. El intervalo de confianza de Wilson al 95 % se sitúa entre el 54.60 % y el 60.34 % [10]. Las cuatro sesiones oscilan entre el 53.70 % y el 61.42 %, con una mediana del 57.04 %.

La tabla 6.2 resume la secuencia de pruebas archivadas. No constituye un experimento controlado entre fechas, porque durante junio cambian el fitness, las intersecciones, el número de spawns y los modelos. Se utiliza para mostrar la evolución observada, no para atribuir causalidad a una modificación aislada. En esta tabla, el fitness medio se calcula directamente sobre `Fitness_Final`; por ello puede diferir ligeramente del promedio de *MeanFit* de la tabla 6.1. El duplicado exacto del 11 de junio se excluye. Cuando el resumen declara más evaluaciones que registros completos de detalle, se conserva la cifra de detalle para el fitness y la vida media, y la tasa de acierto procede de `Test_Summary.csv`.

Tabla 6.2. Evolución de los bloques de test archivados en junio de 2026.

Fecha	Evaluaciones	Acierto	Fitness medio	Vida media
2 de junio	1975	16.51 %	27195.46	46.16 s
5 de junio	2080	18.51 %	26599.02	44.98 s
8 de junio	1560	25.19 %	31295.04	53.13 s
11 de junio	1092	29.67 %	33200.70	52.90 s
15 de junio	431	28.01 %	32758.50	53.90 s
16 de junio	1890	26.51 %	34104.90	55.10 s
17 de junio	540	39.63 %	40305.20	67.50 s
18 de junio	1134	57.50 %	44631.86	77.91 s
22 de junio	550	52.91 %	44296.62	76.20 s
23 de junio	1094	16.27 %	28264.74	50.21 s
26 de junio	467	49.89 %	41869.89	73.34 s
29 de junio	1179	30.42 %	33191.28	61.07 s

Fuente. Elaboración propia a partir de `Fitness_Debug.csv` y `Test_Summary.csv`.

Frente al 8 de junio, el bloque del día 18 sube 32.31 puntos de acierto, un 42.6 % el fitness final medio y un 46.6 % la vida media. Como la serie cae el día 15 y en varias sesiones del 16, las mejoras se aceptan solo tras repeticiones.

Los bloques posteriores muestran por qué no basta con seguir la fecha más reciente. El día 22 mantiene un 52.91 % de acierto y una vida media de 76.20 segundos, todavía cerca de la referencia. El día 23 cae al 16.27 % de acierto y concentra casi la mitad de sus fallos en causas legales. El día 26 mejora hasta el 49.89 % agregado, pero procede de solo dos sesiones muy desiguales: una de 29.66 % y otra de 83.05 %. El día 29, ya con dos sesiones de 590 evaluaciones declaradas cada una, baja al 30.42 % y vuelve a situar STOP_VIOLATION como causa dominante. Ese contraste convierte las sesiones posteriores en material de diagnóstico, no en sustitución directa del bloque del día 18.

6.5 RAZONES DE FINALIZACIÓN

Las 652 finalizaciones por tiempo coinciden con los aciertos declarados en el resumen de test. Entre los 482 fallos hay 454 colisiones, 23 infracciones de stop, tres infracciones de tráfico y dos casos de marcha atrás. No aparecen LAZY, YIELD_VIOLATION, NAV_VIOLATION ni INVALID_BRAIN.

El actor con más colisiones es BP_IntersectionBorder221, con 94 casos. Le siguen NavModifierVolume43, con 64, y NavModifierVolume35, con 63. Los tres reúnen 221 fallos, el 48.7 % de todas las colisiones del bloque. La concentración mantiene como prioridad la revisión geométrica de esos elementos y de los recorridos que conducen hasta ellos.

6.6 COMPORTAMIENTO ANTE SEÑALIZACIÓN

En contexto de parada, el 99.34 % del uso acumulado de los pedales corresponde al freno y el 0.66 % al acelerador. Los registros contabilizan 622 stops y 1692 cedas completados; un mismo vehículo puede superar varias señales, por lo que estas cifras miden eventos y no coches únicos. Las 26 infracciones legales suponen el 2.29 % del bloque.

Estos datos confirman que la señalización modifica la acción del controlador, pero no demuestran por sí solos que toda espera sea correcta. La gran diferencia entre completaciones y muertes legales convive con finalizaciones por tiempo que el detector heurístico puede clasificar como atasco. Para validar una señal concreta siguen siendo necesarias la progresión de ruta, la duración continua de la detención y la inspección del spawn asociado.

6.7 COMPORTAMIENTO EN ROTONDAS

El bloque de test registra 443 entradas en rotonda, 31 completaciones confirmadas y 149 colisiones. Esto equivale a un mínimo del 7.00 % de completaciones y a 33.63 colisiones por cada 100 entradas. El saldo del componente específico es $-187295,02$: las bonificaciones de completado suman 82883.48 puntos, frente a 2408.29 de penalización de entrada y 267770.21 de penalización por aceleración.

El signo negativo no significa necesariamente que el vehículo nunca complete la maniobra, sino que la escala del castigo por acelerar domina sobre la recompensa. La corrección de unidades introducida el 22 de junio intenta resolver este desequilibrio. Los tests posteriores elevan el porcentaje mínimo de completaciones de rotonda respecto al 18 de junio, pero no estabilizan el comportamiento global: el 29 de junio se registran 69 completaciones sobre 363 entradas y 103 colisiones en rotonda, mientras los fallos legales dominan el resultado. Por tanto, la escala de rotonda parece mejor instrumentada, pero no puede validarse de forma aislada mientras el stop siga introduciendo regresiones.

6.8 DIFICULTAD POR PUNTOS DE APARICIÓN

Cada uno de los 54 spawns dispone de 21 observaciones. Los puntos 16, 9 y 25 alcanzan los mayores fitness medios, con 68705.3, 68516.8 y 67472.3; sus tasas de acierto son 95.2 %, 100.0 % y 85.7 %. En el extremo opuesto, los puntos 3, 36 y 42 obtienen 10250.2, 14349.2 y 14722.7, con tasas del 9.5 %, 14.3 % y 19.0 %.

La diferencia entre el mejor y el peor fitness medio supera los 58000 puntos. Como todos tienen el mismo número de observaciones, no procede de un desequilibrio de muestreo. Puede deberse a la geometría inicial, la primera intersección, las trayectorias habilitadas o la adaptación del modelo a esa zona; por ello, los puntos 3, 36 y 42 deben utilizarse en pruebas dirigidas y los puntos 16, 9 y 25 como control de regresión.

6.9 PRUEBAS POSTERIORES HASTA EL 29 DE JUNIO

La sesión `train_2026-06-22_12-04` incorpora la nueva escala de rotonda y la simplificación del tiempo límite del stop. Contiene 613 generaciones y 18379 registros. Su *MeanFit* desciende un 59.0 % entre las primeras y las últimas 50 generaciones, de 40620.05 a 16672.78, y el tiempo medio cae de 67.41 a 36.00 segundos. El cambio más importante aparece en las razones de muerte: 10691 coches, el 58.17 %, terminan por una causa legal y 10672 de ellos son `STOP_VIOLATION`. En el entrenamiento estable del día 18, los fallos legales eran 348, el 2.12 %.

Sin embargo, los dos tests del 22 de junio no reproducen con la misma intensidad esa degradación. Suman 550 evaluaciones, alcanzan un 52.91 % de acierto y presentan un 6.36 % de fallos legales. Este resultado indica que la configuración todavía conserva parte del comportamiento aprendido, pero ya introduce una señal de alarma en stops y validación normativa.

La regresión queda mucho más clara el 23 de junio. El entrenamiento `train_2026-06-23_11-40` contiene 319 generaciones y 8584 registros, con una caída del *MeanFit* del 65.8 % entre las primeras y las últimas 50 generaciones. El 51.93 % de los coches termina por fallo legal y `STOP_VIOLATION` aparece como causa dominante. Los cuatro tests del mismo día reúnen 1094 registros de detalle, pero solo alcanzan un 16.27 % de acierto, con un 48.99 % de fallos legales.

La sesión larga del 25 de junio no se considera candidata a referencia. Aunque contiene 8266 generaciones, su fitness medio queda en 1413.30 puntos, el tiempo vivo medio baja a 8.85 segundos y el 71.49 % de los registros termina por colisión. El entrenamiento corto del 26 de junio tiene solo 30 registros de detalle, insuficientes para extraer una conclusión sólida. El entrenamiento del 29 de junio vuelve a ser completo, con 515 generaciones y 15935 registros, pero mantiene un 63.26 % de fallos legales y `STOP_VIOLATION` como razón dominante.

Los tests del 26 y 29 de junio confirman esa lectura. El día 26 suma 467 evaluaciones y alcanza un 49.89 % agregado, pero el resultado mezcla una sesión de 29.66 % con otra de 83.05 %, demasiado dispar como para aceptarla como nueva referencia. El día 29 aporta un bloque más amplio, con 1180 evaluaciones declaradas y 1179 registros de detalle, pero baja al 30.42 % de acierto. Además, introduce 492 solapes entre coches y mantiene un 42.07 % de fallos legales.

La comparación no aísla por sí sola cuál de las modificaciones provoca el resultado, pero sí demuestra que la referencia del día 18 no debe reemplazarse. La siguiente iteración debe revisar el límite temporal del stop, repetir pruebas cortas modificando un único componente y mantener constantes modelo, spawns y criterios de test antes de lanzar un entrenamiento largo.

Como conclusión experimental, el bloque del 18 de junio mejora la tasa de acierto, reduce colisiones y amplía la evaluación a 54 spawns. También aporta evidencias sobre rotondas, mutaciones y señalización. Aun así, el 40.04 % de colisiones, la diferencia entre spawns y el saldo negativo en rotondas mantienen abierto el problema. Las pruebas del 22 al 29 de junio muestran que una mejora local de fórmula puede degradar otra parte del comportamiento y que los máximos de fitness no bastan. La versión estable debe definirse por un bloque reproducible de entrenamiento y test, con datos completos, modelo identificado y criterios constantes.

Capítulo 7

Normativa y accesibilidad

7.1 PROTECCIÓN DE DATOS

El proyecto se orienta a una aplicación potencial en rehabilitación cognitiva, por lo que debe contemplar desde el diseño la protección de datos personales y, especialmente, de datos de salud. Durante el desarrollo descrito en esta memoria no se ha trabajado con datos reales de pacientes. Los registros analizados corresponden a vehículos autónomos simulados, métricas de entrenamiento y resultados técnicos.

En una futura validación clínica, cualquier uso con personas usuarias deberá ajustarse al Reglamento General de Protección de Datos y a la Ley Orgánica 3/2018 de Protección de Datos Personales y garantía de los derechos digitales [11, 12]. Será necesario definir responsable del tratamiento, finalidad, base jurídica, minimización de datos, conservación, consentimiento informado cuando proceda, medidas de seudonimización y control de acceso. También deberá diferenciarse entre datos necesarios para la evaluación terapéutica y métricas técnicas internas del simulador.

7.2 SEGURIDAD Y USO RESPONSABLE

El simulador no sustituye por sí mismo una evaluación clínica ni una autorización administrativa para conducir. Su función debe entenderse como apoyo a profesionales, entrenamiento controlado y herramienta de observación. Cualquier conclusión sobre capacidad real de conducción debería depender de especialistas y procedimientos establecidos.

Desde el punto de vista técnico, el sistema autónomo genera tráfico artificial. Por tanto, sus fallos no suponen riesgo físico directo durante el entrenamiento virtual, pero sí pueden afectar a la validez de la experiencia. Es importante que las sesiones con pacientes utilicen modelos suficientemente probados para evitar comportamientos incoherentes que confundan al usuario o introduzcan estímulos no deseados.

7.3 ACCESIBILIDAD

La accesibilidad del simulador debe analizarse en relación con las personas a las que se dirige, que pueden presentar alteraciones de atención, memoria, percepción o movilidad. En este TFG no se ha rediseñado la interfaz utilizada por el paciente, por lo que no puede afirmarse que el producto completo haya sido validado como accesible. La aportación realizada se concentra en el tráfico autónomo y afecta de forma indirecta a la carga cognitiva de cada sesión.

El número de vehículos, los puntos del mapa y la frecuencia de situaciones normativas deben poder ajustarse para que la dificultad aumente de forma progresiva. También es importante repetir un mismo escenario bajo condiciones comparables: si el tráfico cambia sin control, resulta difícil saber si una variación en el resultado procede del paciente o de una sesión más exigente. La separación entre entrenamiento y test de la IA y el registro de eventos sientan una base técnica para construir esas repeticiones, aunque todavía falta trasladar estos parámetros a una configuración manejable por el profesional.

La interacción debe contemplar periféricos adaptados, instrucciones breves y legibles y una presentación que no añada estímulos irrelevantes. El rendimiento gráfico y la duración de la prueba también deben vigilarse para reducir fatiga o mareo. Por último, los datos exportados no deberían mostrarse al especialista como un volcado técnico de CSV, sino como indicadores comprensibles y vinculados a maniobras concretas. Estos requisitos deberán revisarse con profesionales y usuarios de ASPAYM antes de utilizar el simulador en una validación clínica.

Capítulo 8

Conclusiones y líneas futuras

8.1 CONCLUSIONES

El punto de partida del trabajo era una ciudad preparada para la conducción del usuario, pero sin un sistema de tráfico capaz de recorrerla de forma autónoma. Las primeras pruebas confirmaron que trasladar soluciones habituales de navegación de personajes a un coche con físicas producía recorridos rígidos y problemas en los cruces. La decisión de sustituir las rutas cerradas por percepción local y una política neuronal permitió avanzar, aunque el resultado no debe interpretarse como un controlador ya resuelto.

La arquitectura implementada conecta once sensores, velocidad, giro y contexto de señalización con una red de 20 entradas, 16 neuronas ocultas y dos salidas. Sus 352 pesos se validan antes de cada inferencia y las consignas se aplican de forma suavizada al componente físico. El gestor evolutivo conserva por separado el modelo histórico y el de sesión, distribuye mutaciones de distinta intensidad y normaliza la selección por punto de aparición. Esta integración funciona dentro del escenario real del simulador y no en una prueba aislada, que era una de las dificultades principales del proyecto.

El desarrollo también ha puesto de manifiesto que la función de fitness y el registro de datos forman parte de la solución, no son tareas posteriores. Una demostración visual podía parecer correcta y ocultar estancamientos, penalizaciones mal equilibradas o resultados concentrados en unos pocos puntos del mapa. La exportación por vehículo permitió revisar esas situaciones y motivó cambios concretos en el fitness, en los bordes de intersección y en la separación entre entrenamiento y test.

Los cuatro tests del 18 de junio reúnen 1134 evaluaciones y alcanzan un 57.50 % de acierto, con un intervalo de confianza del 95 % entre el 54.60 % y el 60.34 %. Las colisiones descienden al 40.04 % y los fallos legales representan el 2.29 %. La mejora frente al bloque del día 8 es notable, pero el rendimiento sigue dependiendo del punto de aparición y las rotondas acumulan un saldo de fitness negativo. El entrenamiento asociado tampoco presenta convergencia clara: aumenta el tiempo de vida mientras desciende el fitness medio entre el inicio y el final de la sesión.

Las ejecuciones posteriores del 22, 23, 26 y 29 de junio refuerzan esa cautela. Después de modificar la escala del fitness y el límite temporal del stop, el entrenamiento del día 22 eleva los fallos legales al 58.17 %, casi siempre por `STOP_VIOLATION`. Los tests de ese mismo día aún conservan un 52.91 % de acierto, pero los del día 23 caen al 16.27 % y muestran un 48.99 % de fallos legales. El día 26 ofrece una sesión favorable, del 83.05 %, pero el agregado de la jornada queda en el 49.89 % por la sesión anterior. El día 29 baja de nuevo al 30.42 %, con un 42.07 % de fallos legales. Esta secuencia se interpreta como una regresión detectada y no como nueva referencia. El resultado muestra el valor práctico de conservar configuraciones y de contrastar cada cambio con más de una métrica.

Por tanto, se ha obtenido una base funcional para generar, entrenar y medir tráfico autónomo, pero todavía no un sistema suficientemente robusto para una sesión clínica. La utilidad inmediata del trabajo reside en que los fallos ya pueden localizarse y compararse con un protocolo común. Las siguientes iteraciones deberán demostrar que las mejoras se mantienen en intersecciones y puntos de inicio distintos antes de aumentar la densidad de tráfico o incorporar nuevos tipos de agentes.

8.2 APORTACIONES REALIZADAS

La primera aportación es el controlador neuronal integrado en el vehículo de Unreal Engine. El trabajo incluye la construcción del vector de 20 entradas, la inferencia de la red y la aplicación suavizada de las dos salidas al sistema Chaos Vehicle. Los sensores no se limitan a detectar obstáculos: en las intersecciones filtran los bordes según la pareja de trigger y maniobra elegida y combinan esa geometría con el estado de semáforos, stops y cedas.

La segunda aportación es el proceso de aprendizaje dentro del propio simulador. El gestor crea poblaciones, conserva sin mutar las dos semillas principales, reparte mutaciones del 3 % y del 6 % y guarda por separado el mejor modelo histórico y el mejor de sesión. La referencia de cada spawn decae con el historial para evitar máximos permanentes, y el uso de puntos y opciones de trayectoria distintos en test permite evaluar el modelo fuera del conjunto que condicionó su entrenamiento.

La tercera aportación es la infraestructura de evaluación. Los Blueprints exportan el resultado de cada vehículo y los resúmenes de generación; posteriormente, los scripts comprueban la calidad de los CSV, agrupan razones de muerte y producen comparaciones por sesión, spawn, familia de mutación, solapes entre vehículos y salida de rotonda. Esta conexión entre simulación y análisis permite justificar una modificación con datos y, como ocurrió entre el 22 y el 29 de junio, reconocer una regresión aunque el cambio local pareciera razonable.

Finalmente, las actas y descripciones fechadas conservan la evolución técnica del proyecto. Gracias a ellas puede reconstruirse por qué se abandonó *Path Finding*, cuándo se reformuló el fitness o cómo se introdujeron los bordes dependientes de la trayectoria. Esta trazabilidad resulta especialmente útil en un desarrollo compartido que deberá continuar después del TFG.

8.3 PROBLEMAS ENCONTRADOS

El primer problema fue adaptar la navegación de Unreal Engine a un vehículo con inercia y radio de giro. NavMesh y *Path Finding* encontraban un destino, pero no producían una conducción natural. Abandonar esa vía obligó a trabajar conjuntamente con Chaos Vehicle, el control mediante Blueprints y los sensores de calzada.

Las intersecciones concentraron buena parte de los fallos posteriores. Un mismo cruce debía ofrecer límites distintos según la salida elegida, y esos límites tenían que coincidir con el trigger que había originado la decisión. La asociación explícita de parejas formadas por dirección y trigger resolvió parte del problema y permitió reutilizar bordes comunes. Aun así, BP_IntersectionBorder221 concentra 94 colisiones en el último bloque, y las rotondas fallan con mayor frecuencia en recorridos que alcanzan salidas posteriores.

El ajuste del fitness fue otra dificultad importante. Premiar avance y supervivencia generó estrategias no previstas, entre ellas permanecer detenido o compensar una colisión con recompensas acumuladas. En rotondas ocurrió el problema contrario: la penalización de aceleración superó ampliamente las bonificaciones. La corrección posterior de la escala coincidió con una regresión masiva de stops, y las pruebas del 26 y 29 de junio confirmaron que una ejecución favorable aislada no basta para cerrar el problema. La instrumentación aumentó la complejidad de los datos, pero evitó continuar ajustando el modelo únicamente a partir de la impresión visual.

Por último, cada entrenamiento exige ejecutar física y renderizado para una población completa. Este coste limita la velocidad con la que pueden probarse cambios y hace especialmente caro descubrir tarde un error de configuración. La persistencia de modelos, la validación de los CSV y los bloques de test repetidos reducen ese riesgo, aunque sigue pendiente un modo de entrenamiento más rápido.

8.4 LÍNEAS FUTURAS

La siguiente iteración debería comenzar por los puntos 3, 36 y 42 y por tres actores concretos: el borde de intersección 221 y los volúmenes de navegación 43 y 35. En cada caso conviene separar un error de geometría de un fallo del controlador: revisar orientación y bordes, repetir la primera maniobra con el modelo del día 18 y comparar distancia recorrida, tiempo detenido y causa de finalización. Los puntos 16, 9 y 25 deben mantenerse como control para detectar regresiones en recorridos que ahora funcionan mejor.

Antes de un nuevo entrenamiento largo debe revertirse o recalibrarse el límite de validación de stop introducido en las últimas iteraciones. La prueba adecuada consiste en mantener el modelo, el fitness restante y los spawns, variar solo ese límite y ejecutar varios bloques cortos de regresión. Después seguirá siendo necesario distinguir una supervivencia útil de un coche inmóvil ante una señal mediante progreso de ruta y duración continua del atasco. Los tests deberán conservar tamaño, modelo y conjunto de spawns para que los intervalos de confianza sean comparables.

También debe equilibrarse el término de rotonda. Las 31 completaciones confirmadas frente a 443 entradas y el saldo neto negativo aconsejan validar por separado la penalización de entrada, la de aceleración y el bonus de salida. Las salidas segunda y tercera requieren pruebas dirigidas, porque acumulan una proporción de muertes superior a la primera.

Para reducir el tiempo entre iteraciones se plantea un modo sin renderizado o con la simulación desacoplada de la presentación. Esta mejora permitiría entrenar más generaciones y reservar la ejecución completa para validar física, señalización y comportamiento visual. También sería conveniente automatizar pruebas sobre intersecciones concretas antes de lanzar una sesión larga.

Los perfiles de conductor normal, inseguro y agresivo, la interacción entre vehículos y la incorporación de peatones o bicicletas deben abordarse cuando la base vehicular sea estable. Añadir agentes antes de resolver las colisiones actuales dificultaría atribuir cada fallo a su causa. Finalmente, cualquier uso con pacientes requerirá definir con ASPAYM un protocolo de sesión, criterios de accesibilidad e indicadores comprensibles para los profesionales.

Agradecimientos

Pendiente de redacción definitiva.

Bibliografía

- [1] L. Fuente, *CognitiveCarSimulatorReloaded - IA*, propuesta de proyecto, 2025.
- [2] E. Romero Yuste, *CognitiveCarSimulator*, Trabajo de Fin de Grado, Grado en Desarrollo de Aplicaciones Interactivas 3D y Videojuegos, Escuela Politécnica Superior de Zamora, 2025.
- [3] Epic Games, *Unreal Engine 5 Documentation*, Epic Developer Community. Disponible en: documentación oficial de Unreal Engine (consulta: 8 de junio de 2026).
- [4] Epic Games, *Chaos Vehicles*, Epic Developer Community. Disponible en: documentación oficial de Chaos Vehicles (consulta: 8 de junio de 2026).
- [5] Epic Games, *Blueprints Visual Scripting in Unreal Engine*, Epic Developer Community. Disponible en: documentación oficial de Blueprints (consulta: 29 de junio de 2026).
- [6] Epic Games, *Traces with Raycasts*, Epic Developer Community. Disponible en: documentación oficial de trazas y raycasts (consulta: 29 de junio de 2026).
- [7] G. Cybenko, "Approximation by superpositions of a sigmoidal function", *Mathematics of Control, Signals and Systems*, vol. 2, pp. 303–314, 1989. DOI: 10.1007/BF02551274.
- [8] A. E. Eiben y J. E. Smith, *Introduction to Evolutionary Computing*, 2.^a ed., Springer, 2015. DOI: 10.1007/978-3-662-44874-8.
- [9] K. O. Stanley y R. Miikkulainen, "Evolving Neural Networks through Augmenting Topologies", *Evolutionary Computation*, vol. 10, n.º 2, pp. 99–127, 2002. DOI: 10.1162/106365602320169811.
- [10] E. B. Wilson, "Probable Inference, the Law of Succession, and Statistical Inference", *Journal of the American Statistical Association*, vol. 22, n.º 158, pp. 209–212, 1927. DOI: 10.1080/01621459.1927.10502953.
- [11] Parlamento Europeo y Consejo de la Unión Europea, *Reglamento (UE) 2016/679, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos*, Diario Oficial de la Unión Europea, 2016. Disponible en: EUR-Lex (consulta: 8 de junio de 2026).

- [12] Jefatura del Estado, *Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales*, Boletín Oficial del Estado, núm. 294, 6 de diciembre de 2018. Disponible en: BOE (consulta: 8 de junio de 2026).

Apéndice A

Fuentes analizadas

A.1 DOCUMENTACIÓN ADMINISTRATIVA Y DE FORMATO

Para la redacción de esta memoria se revisaron los documentos incluidos en INFO/UTILES. Esta documentación sirvió para fijar el formato de portada, comprobar los datos administrativos del trabajo y contrastar la descripción inicial del proyecto con el desarrollo realizado. Los documentos más relevantes fueron:

- portada y normas básicas de estilo de la Escuela de Ingenierías Industrial, Informática y Aeroespacial.
- solicitud de preinscripción del TFG, con título, descripción y tutoría.
- resolución favorable de preinscripción de fecha 18 de mayo de 2026.
- propuesta *CognitiveCarSimulatorReloaded* - IA.
- memoria previa *CognitiveCarSimulator*.
- informe de seguimiento de prácticas HP SCDS.
- memoria final de prácticas del alumno.
- estructura orientativa propuesta por el tutor.

A.2 ACTAS DE REUNIÓN

Se han analizado ocho actas de seguimiento, comprendidas entre el 27/11/2025 y el 19/03/2026. Estas actas permiten justificar las decisiones de arquitectura y los cambios de enfoque realizados durante el proyecto.

A.3 DESCRIPCIONES DEL PROGRAMA

Las descripciones fechadas de los Blueprints se utilizaron para reconstruir el estado de la implementación sin depender únicamente de la versión abierta en el editor. Para el gestor se revisó la carpeta `EVOLUTIONMANAGER`, donde se documentan la creación de generaciones, la asignación de modelos, la mutación, la persistencia y el cambio al modo de test. La carpeta `REDNEURONAL` permitió comprobar la composición de las entradas, las dimensiones de `WeightsIH` y `WeightsHO`, la inferencia y las guardas frente a modelos incompatibles.

El cálculo de aptitud y su instrumentación proceden de `FITNESS`. Se revisaron versiones hasta finales de junio de 2026, incluidas las nuevas métricas de genealogía, rotondas, navegación fuera de calzada, solapes entre vehículos y correcciones de escala de distancia frontal y aceleración. Para la señalización se consultó `INTERSECTIONS`, con la validación aprendida de semáforos y stops, opciones de trayectoria separadas por modo, parejas de dirección y trigger y lógica específica de rotondas. Por último, `OTROS` reúne macros auxiliares, trazas, detección de estancamiento y tareas pendientes que ayudan a interpretar dependencias entre módulos.

A.4 RESULTADOS EXPERIMENTALES

Los resultados documentados proceden de `INFO/ANALISIS_DATOS/Analisis`. La referencia principal de entrenamiento es `train_2026-06-18_11-21`, con 548 generaciones y 16432 registros de vehículos. La evaluación agrega las cuatro carpetas de test del 18 de junio, que suman 21 ejecuciones y 1134 registros sobre 54 spawns. La marca horaria forma parte del identificador y no se utiliza como variable experimental.

Para reconstruir la evolución se revisaron además los bloques de los días 2, 5, 8, 11, 15, 16, 17, 22, 23, 26 y 29. Las carpetas `test_2026-06-11_11-55` y `test_2026-06-11_13-08` contienen exactamente el mismo CSV de detalle y se contabilizan una sola vez. El test del día 15 conserva 431 de las 432 filas declaradas. En las sesiones nuevas también se conserva visible la diferencia entre evaluaciones declaradas y registros de detalle cuando existe un pequeño descuadre. Esta incidencia y las coberturas de cada sesión se mantienen visibles en el capítulo de resultados.

También se analizaron los entrenamientos de los días 11, 16, 17, 18, 22, 23, 25, 26 y 29 de junio. Los bloques posteriores al día 18 no sustituyen a la referencia estable porque muestran regresiones normativas, entrenamientos incompletos o resultados demasiado variables entre sesiones. Se conservan para documentar el efecto de los cambios de fitness, stop, rotondas y diagnóstico de solapes. La figura del capítulo 6 se ha regenerado en PDF vectorial a partir del `Training_Summary.csv` del día 18, y tanto los datos como el código PGFPlots quedan archivados en `MEMORIA/assets`.

A.5 CONVERSACIONES CON ASISTENTES DE IA

La carpeta INFO/CONVERSACIONES_IA contiene conversaciones mantenidas durante el desarrollo con ChatGPT, Claude y Gemini. Se han revisado 48 ficheros Markdown: 13 de ChatGPT, 28 de Claude y 7 de Gemini. En conjunto reúnen 769 bloques de consulta o intervención del usuario. No se han tratado como fuente primaria de resultados, sino como trazabilidad del proceso de trabajo: preguntas de depuración, análisis de entrenamientos, selección de modelos, organización del proyecto, uso de Unreal Engine y preparación de scripts auxiliares.

El criterio de incorporación ha sido selectivo. Las consultas menores sobre manejo del editor, avisos de LaTeX o dudas puntuales solo se han usado para entender el contexto. En cambio, sí se han tenido en cuenta las conversaciones que ayudan a explicar decisiones técnicas: precisión de parada, detección de INVALID_BRAIN, coches inmóviles sin justificación, separación train/test, duplicados de modelos, diagnóstico de rotondas, análisis de caídas de rendimiento y regresiones por STOP_VIOLATION. El anexo B recoge una versión corregida y mejorada de los prompts más representativos, junto con la comprobación realizada antes de aplicar cada idea.

Apéndice B

Prompts utilizados

B.1 CRITERIO DE DOCUMENTACIÓN

Este anexo documenta una selección representativa de los prompts utilizados durante el desarrollo. No se reproducen de forma literal: se presentan en una versión revisada, más clara y reutilizable, manteniendo el objetivo real de cada consulta. La decisión responde a dos motivos. Primero, muchos prompts originales formaban parte de conversaciones largas, con adjuntos, correcciones sucesivas y mensajes de seguimiento que no resultan legibles como evidencia académica. Segundo, el interés del anexo no es conservar cada frase escrita, sino explicar cómo se utilizó la IA generativa dentro del proceso de ingeniería.

Las respuestas de los asistentes se trataron como apoyo para generar hipótesis, ordenar alternativas y proponer comprobaciones. Ninguna decisión se incorporó únicamente por aparecer en una respuesta: se contrastó con Blueprints, CSV, informes de análisis, pruebas en Unreal Engine o revisión manual. Las consultas menores sobre uso básico del editor, avisos de LaTeX o formato no se incluyen salvo que ayudasen a reconstruir una decisión técnica.

B.2 MATERIAL REVISADO

La carpeta INFO/CONVERSACIONES_IA contiene 48 conversaciones exportadas en Markdown. La tabla B.1 resume el material revisado.

Tabla B.1. Conversaciones de IA revisadas para el anexo de prompts.

Asistente	Ficheros	Bloques	Uso principal
ChatGPT	13	209	Depuración de Blueprints, scripts de análisis, modelos y memoria.
Claude	28	292	Análisis de entrenamientos, regresiones, stops, rotondas y selección de modelos.
Gemini	7	268	Apoyo inicial con Unreal Engine, organización y consultas puntuales.

Fuente. Elaboración propia a partir de INFO/CONVERSACIONES_IA.

B.3 PROMPTS DEPURADOS INCORPORADOS

1. Prompt B.1. Análisis del estado del programa y mejora de parada

Conversación base. ChatGPT, mejora de parada precisa.

Objetivo. Mejorar la precisión de parada ante señales de stop y semáforos sin depender de una recompensa genérica de supervivencia.

Prompt depurado.

Analiza las descripciones actuales del controlador de IA, señales de stop, semáforos, fitness y gestor evolutivo. Quiero que el modelo aprenda a detenerse cerca de `StopTargetLocation` cuando exista obligación de parar. Identifica qué información ya recibe la red, qué parte falta en el fitness y qué cambios son necesarios. Evita constantes arbitrarias: si propones umbrales, indica de qué variable del simulador deben derivarse. Separa la propuesta en pasos verificables y añade qué métricas habría que exportar para comprobar si la mejora funciona.

Respuesta aprovechada. Se aprovechó la idea de distinguir entre tener información de parada como entrada y tener presión explícita en el fitness para aproximarse correctamente a la línea.

Comprobación realizada. Se revisaron las descripciones fechadas de red neuronal, fitness e intersecciones, además de los CSV con tiempos de espera y completaciones de stop.

Uso final en el proyecto. La memoria recoge la validación de stops, la ventana de parada, el aprendizaje de umbrales y la necesidad de diferenciar espera correcta de estancamiento.

2. Prompt B.2. Penalización de retroceso y estancamiento injustificado

Conversación base. Gemini, organización del proyecto, y ChatGPT, mejora de parada precisa.

Objetivo. Evitar que el entrenamiento premie coches que sobreviven sin avanzar, retroceden o permanecen inmóviles sin una causa de tráfico válida.

Prompt depurado.

Revisa la lógica de fitness y detección de muerte para vehículos que retroceden o se quedan parados. Necesito diferenciar una parada legítima, por semáforo, stop, ceda u obstáculo delante, de una parada que solo alarga la vida del coche sin aportar recorrido útil. Propón una lógica basada en velocidad real, contexto de tráfico, sensores frontales y tiempo de vida. No uses números fijos sin justificación. Indica qué razón de muerte o métrica de diagnóstico debe registrarse para validar el cambio.

Respuesta aprovechada. Se aprovechó la separación conceptual entre parada justificada y comportamiento perezoso, además de la necesidad de penalizar el retroceso con una causa trazable.

Comprobación realizada. Se comprobó con los informes de entrenamiento, las razones de muerte LAZY, BACKWARDS y TIMEFINISHED, y los casos de coches vivos sin progreso.

Uso final en el proyecto. El capítulo 5 describe la penalización por marcha atrás, estancamiento y navegación no válida, y el capítulo 6 advierte que el tiempo de vida no puede usarse como único indicador.

3. Prompt B.3. Diagnóstico de salida de calzada y coches bloqueados

Conversación base. Claude, análisis de problemas en datos de entrenamiento y comportamiento de vehículos.

Objetivo. Explicar por qué algunos coches fuera de calzada o retenidos en señales llegaban a finalizar por tiempo en lugar de morir por una causa clara.

Prompt depurado.

Analiza el entrenamiento adjunto y las descripciones de fitness, intersecciones, gestor evolutivo y red neuronal. Busca coches que sobrevivan demasiado tiempo fuera de calzada o parados ante stops y cedas. Distingue hipótesis de evidencia en los CSV. Calcula qué condiciones deberían activar NAV_VIOLATION, LAZY, STOP_VIOLATION o TIMEFINISHED. Propón soluciones dinámicas, basadas en variables existentes, y explica cómo verificarlas con métricas exportadas.

Respuesta aprovechada. Se aprovechó el análisis de interacción entre penalización acumulada, velocidad casi nula, contexto ForceStop y reinicio de contadores.

Comprobación realizada. Se contrastó con registros de navegación fuera de calzada, finalizaciones por tiempo, penalizaciones acumuladas y ausencia de muertes NAV_VIOLATION en determinadas sesiones.

Uso final en el proyecto. La memoria incorpora la salida de calzada como problema de acumulación temporal y de penalización, y no como simple colisión geométrica.

4. Prompt B.4. Actualización del analizador de CSV

Conversación base. ChatGPT, ajuste del código de análisis y gráficas de tiempo vivo.

Objetivo. Mantener los scripts de análisis alineados con las columnas nuevas exportadas por los Blueprints.

Prompt depurado.

Actualiza el script de análisis para los CSV actuales. Lee primero las cabeceras de Fitness_Debug.csv, Training_Summary.csv y Test_Summary.csv. Añade compatibilidad con las nuevas columnas de stop, ceda, suavizado de dirección, genealogía, rotondas y solapes entre vehículos. El script debe validar cobertura, duplicados, filas incompletas, distribución de razones de muerte, evolución de fitness, vida media y diferencias por spawn. Si una columna no existe en una sesión antigua, debe degradar con aviso y no fallar.

Respuesta aprovechada. Se aprovechó el enfoque de script robusto por cabeceras, con diagnóstico de cobertura y generación de informes comparables entre sesiones.

Comprobación realizada. Se ejecutaron análisis sobre sesiones de abril, mayo y junio, comprobando informes, gráficas y coherencia con los CSV originales.

Uso final en el proyecto. El capítulo 6 se apoya en métricas calculadas a partir de estos CSV y conserva explícitamente incidencias de cobertura o duplicados.

5. Prompt B.5. Separación de entrenamiento y test

Conversación base. ChatGPT, modificación de triggers y refresco de spawns.

Objetivo. Evitar que el rendimiento de test se midiera sobre los mismos recorridos que condicionaban el entrenamiento.

Prompt depurado.

Revisa la lógica de spawns y triggers de dirección. Quiero separar entrenamiento y test: en entrenamiento deben usarse solo los puntos y trayectorias habilitados para aprender, mientras que el test debe evaluar un conjunto independiente y completo. Indica qué variables deben pertenecer al trigger, cuáles al gestor evolutivo y en qué momento conviene refrescar la lista de spawns para evitar mezclas entre modos. Propón comprobaciones en CSV para verificar que cada ejecución usa el conjunto correcto.

Respuesta aprovechada. Se aprovechó la necesidad de separar TrainMode, listas válidas por modo, refresco de spawns y trayectorias permitidas.

Comprobación realizada. Se revisaron BP_Trigger, RefreshSpawnPoints, los resúmenes de test y la distribución de observaciones por los 54 spawns.

Uso final en el proyecto. La memoria presenta la separación train/test como decisión metodológica clave y advierte que el test no debe interpretarse como nueva fase de aprendizaje.

6. Prompt B.6. Selección y deduplicación de modelos

Conversación base. ChatGPT, duplicados de modelos, y Claude, selección de modelo para reentrenamiento.

Objetivo. Reducir pruebas repetidas sobre backups equivalentes y seleccionar candidatos de reentrenamiento con criterios trazables.

Prompt depurado.

Analiza los backups .sav de modelos y los tests asociados. Primero identifica modelos duplicados o casi idénticos comparando sus pesos, para no repetir evaluaciones. Después ordena los candidatos de reentrenamiento usando tasa de acierto, fitness medio, vida media, razones de muerte, estabilidad por spawn y coherencia entre entrenamiento y test. No elijas solo por *BestFit*. Explica qué modelo conviene conservar como base, cuál usar como alternativa y qué pruebas faltan antes de aceptar el cambio.

Respuesta aprovechada. Se aprovechó la idea de no tratar cada copia fechada como un modelo independiente si sus pesos no aportaban una política distinta.

Comprobación realizada. Se compararon pesos, informes de test, métricas por sesión y diferencias entre SuperCarModel y SessionCarModel.

Uso final en el proyecto. El capítulo 5 explica la persistencia de modelos y el capítulo 6 evita sustituir la referencia por sesiones posteriores no reproducibles.

7. Prompt B.7. Diagnóstico de rotondas e intersecciones

Conversación base. ChatGPT, revisión de comportamiento del coche y análisis de modelos.

Objetivo. Analizar por qué el vehículo fallaba en rotondas, especialmente en salidas posteriores, y cómo ajustar la geometría o el fitness sin perder generalización.

Prompt depurado.

Revisa el test del modelo y las descripciones de intersecciones. Me interesa entender el comportamiento en rotondas: entrada, permanencia, elección de salida, aceleración, colisiones y completado. Separa problemas de geometría, escala del fitness y percepción por sensores. Si propones mover puntos de spline o modificar bordes de intersección, justifica cómo afectará a la trayectoria y qué métrica permitirá verificar la mejora. Incluye una revisión específica para primera, segunda y tercera o posteriores salidas.

Respuesta aprovechada. Se aprovechó la distinción entre problema geométrico, problema de recompensa y problema de percepción contextual.

Comprobación realizada. Se revisaron métricas de entrada y completado de rotonda, colisiones, saldo específico de rotonda y análisis por salida.

Uso final en el proyecto. Los capítulos 5 y 6 describen las rotondas como subsistema propio, con penalización de aceleración, completaciones confirmadas y limitaciones de escala.

8. Prompt B.8. Análisis de regresión tras cambios de código

Conversación base. Claude, análisis de regresión y errores en stops, con atención a STOP_VIOLATION.

Objetivo. Entender por qué una modificación local podía empeorar el comportamiento global, especialmente en stops.

Prompt depurado.

Compara dos ejecuciones del mismo modelo antes y después de los cambios en intersecciones, fitness y red neuronal. Usa los informes y CSV para cuantificar la caída de rendimiento. Localiza qué razones de muerte aumentan, qué cambios de Blueprint coinciden temporalmente y qué hipótesis explican la regresión. No atribuyas causalidad sin prueba: separa correlación, evidencia directa y comprobaciones pendientes. Propón una secuencia de pruebas cortas en la que solo cambie un componente cada vez.

Respuesta aprovechada. Se aprovechó la metodología de comparar el mismo modelo bajo condiciones próximas, localizar cambios de Blueprints y mirar razones de muerte antes de aceptar una mejora.

Comprobación realizada. Se contrastaron los bloques del 18, 22, 23, 26 y 29 de junio, con especial atención a STOP_VIOLATION y a la variabilidad entre sesiones.

Uso final en el proyecto. La conclusión experimental indica que una mejora local del fitness puede degradar stops o generalización, por lo que la versión estable debe definirse por bloques reproducibles.

9. Prompt B.9. Mutación dinámica y persistencia de modelos

Conversación base. Claude, ratio dinámico basado en población, y ChatGPT, mejora del guardado de modelos.

Objetivo. Mejorar la creación de generaciones y el guardado de modelos sin depender de proporciones fijas ni duplicar copias equivalentes.

Prompt depurado.

Revisa `StartGeneration`, `EndGeneration` y `SaveWeightsToSlot`. Quiero que la población se reparta de forma dinámica según `PopulationSize`, conservando un individuo sin mutar del mejor modelo histórico y otro del mejor modelo de sesión. El resto debe distribuirse entre mutaciones y candidatos aleatorios o derivados, sin números mágicos. Además, revisa el criterio de guardado para evitar duplicados de pesos, pero sin perder un modelo que tenga fitness o metadatos relevantes. Explica qué campos deben registrarse para auditar la decisión.

Respuesta aprovechada. Se aprovechó el enfoque de ratios dependientes de población y la necesidad de guardar modelo, fitness y procedencia de forma coherente.

Comprobación realizada. Se revisaron las descripciones de `EVOLUTIONMANAGER`, los backups de modelos y las métricas de genealogía por índice de coche.

Uso final en el proyecto. La memoria describe las familias de mutación, el elitismo, `SessionCarModel`, `SuperCarModel` y la copia fechada del modelo anterior.

10. Prompt B.10. Organización del proyecto y reproducibilidad

Conversación base. Gemini, organización del proyecto, ChatGPT, limpieza de logs, y Gemini, errores de módulos en Unreal Engine.

Objetivo. Mantener el proyecto reproducible pese a trabajar con Unreal Engine, Blueprints, binarios, logs extensos y resultados experimentales pesados.

Prompt depurado.

Ayúdame a organizar el repositorio y el flujo de trabajo para un proyecto de Unreal Engine con Blueprints, modelos guardados, logs, CSV de entrenamiento y memoria en LaTeX. Distingue qué archivos deben versionarse, cuáles son temporales, cuáles deben archivar como evidencia experimental y cómo nombrar carpetas para reconstruir una sesión. Propón además un script o procedimiento para limpiar logs irrelevantes conservando warnings, mensajes propios de Blueprints y datos útiles de depuración.

Respuesta aprovechada. Se aprovechó la separación entre evidencia de proyecto, resultados generados, logs temporales y documentación final.

Comprobación realizada. Se revisó la estructura `INFO`, los scripts de análisis, los ficheros temporales de LaTeX y la limpieza de imágenes generadas no necesarias.

Uso final en el proyecto. La memoria conserva un anexo de fuentes, un anexo de prompts, reglas de limpieza del repositorio y una distinción entre datos primarios y salidas generadas.